第6卷 第2期 计 量 经 济 学 报 Vol. 6, No. 2
2026年3月 China Journal of Econometrics Mar., 2026

doi: 10.12012/CJoE2025-0454

多源数据驱动的金融大语言模型文本分析与交易策略

樊嘉诚 [1], 吴俊樊 [2], 林建浩 [1]

(1. 中山大学岭南学院, 广州 510275; 2. 招商证券资产管理有限公司, 深圳 518026)

摘 要 金融市场中信息来源多元且结构复杂, 如何对其系统整合并形成可交易的投资信号, 已成为资产定价研究与实践中的核心问题. 本文基于多源数据和金融大语言模型, 构建了一个涵盖新闻、股价、宏观分析及信号生成模块的智能决策系统, 以 2020–2024 年沪深 300 指数成份股为样本, 系统评估了大语言模型生成的投资决策信号的预测能力. 首先, 根据买入、持有和卖出信号构建了三类投资组合, 净值曲线与风险收益指标分析表明, 买入信号组合的超额收益 (23.83%) 显著优于持有信号 (6.96%) 和卖出信号 (−15.08%), 验证了方向性信号具备有效的收益预测能力. 其次, 本文引入买入评分机制, 对买入信号进行细粒度分类并构建投资组合. 结果显示, 高评分的多头组合累计超额收益高达 99.20%, 夏普比率为 0.65, 换手率仅为 41.16%, 表明买入评分对未来收益具有显著的增量预测能力且具有一定的持仓持续性. 最后, 本文利用券商深度研究报告对大语言模型进行微调, 进一步实现了投资策略性能的显著提升. 本文系统展示了金融大语言模型在实证资产定价中的应用潜力, 验证了其在投资信号识别、策略构建及模型微调方面的有效性, 为人工智能赋能金融决策提供了可行路径.

关键词 大语言模型; 实证资产定价; 经济金融文本分析

收稿日期: 2025-08-20

基金项目: 国家自然科学基金 (72273156, 723B2024); 国家社会科学基金重大项目 (24ZDA042); 国家社会科学基金重点项目 (22AZD121)

Supported by National Natural Science Foundation of China (72273156, 723B2024); Major Program of National Social Science Fund of China (24ZDA042); Key Program of the National Social Science Fund of China (22AZD121)

作者简介: 樊嘉诚, 博士研究生, 研究方向: 资产定价, 金融计量, E-mail: fanjch7@mail2.sysu.edu.cn; 吴俊樊, 硕士, 研究方向: 资产定价, E-mail: wujunfan@cmschina.com.cn; 通信作者: 林建浩, 博士, 教授, 博士生导师, 研究方向: 宏观金融, 人工智能与数字经济, E-mail: linjh3@mail.sysu.edu.cn.

本文所使用的数据和代码请参见科学数据银行 (ScienceDB) 期刊社区, DOI: 10.57760/sciencedb.j00214.00180 和 CSTR: 31253.11.sciencedb.j00214.00180. 若使用文中数据信息, 请注明引文和数据出处.

中国知网 https://www.cnki.net

Text Analysis and Trading Strategies with Multi-Source Financial Large Language Models

FAN Jiacheng[1], WU Junfan[2], LIN Jianhao[1]

(1. Lingnan College, Sun Yat-sen University, Guangzhou 510275, China; 2. China Merchants Securities Asset Management Co., Ltd., Shenzhen 518026, China)

Abstract In financial markets, information sources are diverse and structurally complex, and how to systematically integrate such information into tradable investment signals has become a central issue in asset pricing research and practice. This study constructs an LLM-based decision-making system, incorporating multi-source data such as news texts, stock prices, and macroeconomic conditions. Using the constituents of the CSI 300 Index from 2020 to 2024 as the sample, we systematically evaluate the predictive power of investment signals generated by LLMs. First, we construct three types of portfolios based on buy, hold, and sell signals. Analysis of cumulative returns and risk-return metrics shows that the buy-signal portfolio achieves significantly higher excess returns (23.83%) than the hold (6.96%) and sell (−15.08%) signal portfolios, validating the directional predictive power of the generated signals. Second, to further enhance performance, we introduce a buy-score mechanism that classifies buy signals into finer categories and builds portfolios accordingly. Results show that the high-score long portfolio achieves a cumulative excess return of 99.20%, a Sharpe ratio of 0.65, and a turnover rate of 41.16%, indicating that the buy score has strong incremental predictive power and that the holdings exhibit persistence. Finally, we fine-tune the LLMs using in-depth research reports from brokerages, resulting in a significant improvement in strategy performance. Overall, this study demonstrates the value of financial LLMs in empirical asset-pricing applications, validates their effectiveness in signal identification, strategy construction, and model tuning, and provides a practical path for integrating AI into financial decision-making.

Keywords large language models; empirical asset pricing; economic and financial text analysis

1 引言

在金融市场中, 投资者情绪和市场波动通常通过新闻报道、社交媒体和研究报告等非结构化文本数据得以体现. 既有研究表明, 文本信息对股票收益与波动具有显著的预测能力, 并在资产定价中占据重要地位 (Bybee et al., 2023; Aleti and Bollerslev, 2025; 游家兴和吴静, 2012; 林建浩等, 2022). 然而, 随着数据规模持续扩张、信息来源日益多元, 依赖关键词技术的传统文本分析方法在处理复杂金融环境时逐渐显现出局限性. 一方面, 传统文本分析方法对不同来源、不同信息粒度文本的联合建模能力有限, 难以捕捉跨渠道、跨时间的信息传递与相互影响; 另一方面, 这些方法通常依赖预设的情感词典或词频统计等方法, 将高维语义信息压缩为低维特征, 难以充分刻画文本信息的复杂性和时变性, 从而限制了其在市场叙事变化和定价机制动态演化中的适用性.

中国知网 https://www.cnki.net

与此同时, 在建设金融强国与加快发展新质生产力的战略布局下, 推动人工智能技术与金融业深度融合已成为深化金融供给侧结构性改革的重要方向. 2023 年中央金融工作会议强调要做好数字金融等 “五篇大文章”, 提升资本市场信息治理效能, 2024 年国务院《政府工作报告》明确提出开展 “人工智能 +” 行动. 在数据要素市场化配置改革持续深化的背景下, 我国资本市场与外部市场的联动性日趋增强, 但市场内部的信息处理效率和资源配置效率仍有待提升. 在此背景下, 如何有效利用前沿人工智能技术提升金融市场的信息处理能力和定价效率, 具有重要的理论价值和现实意义.

作为人工智能技术的代表性成果, 大语言模型 (large language models, LLMs) 在自然语言处理领域展现出卓越性能, 为经济金融文本分析提供了新的研究视角与方法路径 (林建浩和孙乐轩, 2025). 借助 LLMs, 从海量、多源、异构文本中提取投资相关信息成为可能, 其优势主要体现在三类互补能力上: 一是对经济叙事和市场预期的近似刻画能力, 使模型能够从新闻、公告、研究报告及宏观评论中提取有效信息, 甚至模仿人类生成相应的信念、预期或经济决策 (Bastianello et al., 2024; Zarifhonarvar, 2026); 二是对多源信息的整合能力, 使模型能够将分散的、多样化的文本信息映射到统一的语义空间, 并在零样本或少样本条件下对新文本进行分析和理解 (Nie et al., 2017; 何勇等, 2025); 三是推理与规则归纳能力, 使模型能够识别事件之间的因果联系, 总结一般性规则或模式 (Brown et al., 2023; Wei et al., 2022).

本文在多源数据背景下提出了一种基于金融大语言模型的智能投资决策系统, 涵盖新闻文本、股价数据和宏观经济等多维信息的整合模块. 具体而言, 新闻分析模块对海量新闻进行逐篇总结与去重处理, 并按月汇总生成新闻信息; 股价分析模块识别关联公司并整理风险收益指标, 结合月度股价汇总形成价格动态信息; 宏观经济分析模块提供研究报告的月度总结, 为投资决策补充宏观背景; 信号生成模块则基于上述信息构建月度投资信号与全面投资建议, 并引入买入评分机制, 对投资组合进行排序与评估. 在此基础上, 以 2020–2024 年沪深 300 成份股为样本, 系统评估了大语言模型生成的投资决策信号的预测能力. 实证结果表明, LLMs 能够有效提取多源金融数据信息, 生成具有区分度的投资信号. 其中, “买入” 信号组合显著跑赢 “持有” 与 “卖出” 组合, 并且买入评分机制进一步增强了信号的预测能力, 其中高评分的多头组合累计超额收益高达 99.20%, 夏普比率为 0.65. 基于买入评分排序的多头投资组合, 本文构建了基于大语言模型的沪深 300 指数增强策略, 在考虑交易成本与调仓等实际因素后, 该策略依然表现稳健——年化收益率约为 14%, 最大回撤不超过 30%. 消融实验表明, 新闻和股价信息对策略效果影响最大, 而宏观经济信息作用相对有限. 最后, 本文利用 A 股非沪深 300 指数成份股的研究报告文本对 LLMs 进行了金融领域微调, 结果显示微调显著增强了模型的投资决策能力.

本文在人工智能与金融学的交叉领域取得了一定突破, 主要贡献体现在以下两个方面: 一是设计并实现了一个基于大语言模型的模块化智能投资决策系统. 该系统由多个经济分析与信号生成模型组成, 整合新闻、市场与宏观等多源数据, 不仅具备良好的可扩展性和用户适配性, 还引入了具有可解释性的投资信号与细粒度评分机制, 提升了决策透明度与可信度. 二是构建了针对金融语境的大语言模型微调方案. 本文利用深度研究报告生成的问答数据对模型进行微调, 显著增强了其对金融文本的理解和投资信号识别能力, 从而提升了策略的收益表现、风险控制与决策稳健性.

中国知网 https://www.cnki.net

本文余下的结构安排如下: 第 2 节对相关文献进行梳理; 第 3 节详细说明了本文智能投资决策系统架构和各模块的功能; 第 4 节介绍了数据与基座模型, 以及投资组合的实证结果; 第 5 节使用金融语料数据对大语言模型进行微调, 考察了金融知识增强对投资决策质量的影响; 第 6 节总结全文, 讨论未来的研究方向.

2 文献综述

文章将从三个方面进行文献评述: 一是基于文本分析的资产定价研究; 二是经济金融领域的大语言模型与智能体; 三是另类数据与多模态信息在金融分析中的应用.

2.1 基于文本分析的资产定价研究

随着叙事经济学的兴起 (Qwen et al., 2025), 现有研究主要从文本情绪、主题关注度等角度研究新闻文本叙事对资产价格的影响. 例如, Antweiler and Frank (2004)、Tetlock et al. (2008) 研究发现, 新闻媒体文本中的情绪信息能够预测未来的股市波动, 且消极报道较多的公司往往股价和盈利表现较差. Ke et al. (2020) 基于新闻文本情绪分析和监督学习框架提出了一个股票收益预测模型, 并在实证中取得了优异的超额收益. Alqahtani et al. (2020) 基于新闻文本构造了经济市场波动率指数, 该指数的上升对股票市场回报产生了显著且负面的影响. Bybee et al. (2023) 在 ICAPM 框架下利用 LDA (latent dirichlet allocation) 主题模型构建定价因子, 实证表明引入文本信息的模型能更好解释股票收益异象并提升超额收益. Aleti and Bollerslev (2025) 则结合实时新闻数据和高频资产回报, 估计出一个基于新闻信息流的随机折现因子 (SDF), 发现与货币政策和金融相关的新闻尤为重要.

在中国 A 股市场中, 新闻媒体报道的相关文本同样是资产定价中的重要影响因素. 具体地, 游家兴和吴静 (2012) 运用文本分析方法构建了媒体情绪指数, 发现新闻报道中的情绪过于高涨或低落会导致股票价格偏离其基本价值水平, 尤其在公司信息不透明时这种资产误定价更为显著. 姜富伟等 (2021) 在 Loughran and Mcdonald (2011) 词典的基础上构建了中文金融情感词典, 发现该词典可以更准确地衡量我国媒体文本情绪, 对股市回报有显著的预测能力. 林建浩等 (2022) 改进了 Ke et al. (2020) 的有监督文本情绪模型, 并应用于沪深 300 指数成份股的海量新闻数据以构建投资策略. 总体而言, 现有研究多从文本信息中提取可量化特征并嵌入预测或定价框架, 较少关注语言模型对文本叙事本身的理解、概括与判断能力; 本文利用 LLMs 的生成式推理优势, 通过对文本内容进行综合性分析与情境化判断, 刻画更贴近真实投资决策的信息处理过程, 从而为文本驱动的资产定价与交易策略研究提供有益补充.

2.2 经济金融领域的大语言模型与智能体

在经济金融领域的文本分析中, 基于关键词的 “词袋” 模型 (bag-of-words, BOW) 长期占据主导地位. 这类模型的核心思想是将文本表示为一个包含所有词语的集合 (即词袋), 而词语之间是独立的, 故忽略了词语在文本中的顺序关系及其本身含义. 大语言模型显著改变了经济金融研究的既有范式 (程兵, 2023; 洪永淼和汪寿阳, 2024), 对文本分析应用的重要影响体现在, 研究不再局限于对单一文本特征 (如情绪或关注度) 的提取, 而是更系统地挖掘文本所蕴含的丰富信息与经济含义. 林建浩和孙乐轩 (2025) 对 LLMs 在经济与金融文本分析

中国知网　https://www.cnki.net

中的应用进行了系统综述, 本文不再重复一般性讨论, 而聚焦其在金融市场与资产定价领域的相关进展. 例如, Kim and Kikolaev (2024) 提出了一个 LLMs 架构, 用于刻画财务报表中叙事文本与数值信息之间的交互关系, 发现叙事语境能够显著增强会计数字的解释力. 姜富伟等 (2024) 训练了一个中文金融大语言模型并进行了金融市场情绪测度和资产价格风险预测, 结果显示 LLMs 在预测性能上显著优于传统文本分析方法.

随着大语言模型在理解、推理与信息整合能力上的持续提升, 其应用逐渐从 "文本表示与预测" 拓展至 "自主决策与任务执行", 推动了智能体 (AI agents) 的兴起. 经济金融智能体是能在复杂市场环境中自主感知信息、处理数据并做出优化经济金融决策 (如交易、投资、预测) 的智能程序或系统. 现有研究主要聚焦于经济金融分析、股票交易与因子挖掘 (Lee et al., 2025; Xiao et al., 2025)[1]. 首先, 经济金融分析智能体侧重利用大语言模型对金融文本进行深度理解与推理以支持选股与策略生成, 代表性的智能体包括 AlphaFin (Li et al., 2023)、FinSphere (Han et al., 2025) 和 TradingAgents (Xiao et al., 2025) 等. 其次, 股票交易智能体在此基础上引入反思、记忆或多代理辩论机制以提升决策稳健性, 典型框架如分层记忆与代理交流的 TradingGPT (Li et al., 2023) 或 FinMem (Yu et al., 2024). 最后, 因子挖掘智能体则将大语言模型用于生成与筛选产生超额收益的因子, 并通过人机迭代或循环测试框架加以验证, 如 AlphaGPT (Wang et al., 2025; Yuan et al., 2024) 和 QuantAgent (Wang et al., 2024) 等. 与之相比, 本文综合利用新闻、股价和宏观经济等多源信息, 基于 LLMs 的生成式分析能力与任务导向微调机制构建交易策略, 并在纳入实际交易因素的回测中检验其有效性, 为相关研究提供更贴近真实市场环境的经验证据.

2.3 另类数据与多模态信息在金融分析中的应用

传统金融研究长期以财务报表、宏观指标和股价数据为核心, 而近年来, 涵盖文本、图像、音频和视频等形式的 "另类数据" (Alternative Data) 与多模态信息受到广泛关注. 综述性工作, 如 Sun et al. (2008) 和 Cao et al. (2024) 全面总结了多种另类数据在回报预测、风险管理与信用评估等领域的潜在应用场景与研究路径. 在具体应用层面, Jiang et al. (2023) 将股票历史价格转换为股价图像, 再利用卷积神经网络 (CNN) 分析来自动识别最具预测力的价格变化模式, 发现基于图像构建的交易策略具有跨市场与跨时间尺度的稳健性. Hu and Ma (2025) 从视觉 (图像)、语音 (音频) 和语言 (文本) 三个维度量化创业路演中演讲者的说服力, 发现积极热情的表达显著提升融资概率, 但随后表现较差. 这是因为这些表达主要通过影响投资者形成不准确的预期信念, 而非传递更多真实项目价值.

在国内研究方面, 廖理等 (2021) 利用中国消费行业上市公司 2015–2018 年电商销售数据, 检验线上消费行为是否向资本市场传递公司价值信息. 结果表明, 电商销售数据蕴含重要的基本面信息, 其预测能力在 "线上收入占比高、关注度低、成长性强、信息透明度高" 的公司中更强, 揭示了消费侧另类数据在新兴市场中的信息价值与定价能力. 何勇等 (2023) 基

[1]与此同时, 智能投顾正成为智能体的重要应用方向. 与策略导向的交易型智能体不同, 智能投顾更强调面向投资者的个性化与交互式资产配置和财富管理服务. 例如, Yang et al. (2023) 构建了开源可扩展的 AI 平台 FinRobot, 能够动态整合多源大语言模型以应对不同金融任务和市场环境. 何勇等 (2025) 开发的 AI 智能体 "智投指南 FinCompass", 可以结合多模态数据为投资者生成每日 A 股推荐投资清单.

中国知网 https://www.cnki.net

于财经短视频、图像及文本数据构建因子增广回归与深度神经网络模型, 发现这些多模态数据在中国股票市场中能够提取与股价相关的信号, 并为投资组合提供超额收益. 与本文相近, 何勇等 (2024) 基于 BERT 与 ChatGPT 构建了适用于中国股票市场的投资交易模型, 研究表明大模型能够有效提取新闻情绪并解析传统金融数据, 在股票预测与组合构建中具有显著信息增益与收益提升效应. 不同于该研究, 本文在文本数据的使用上并非仅关注情绪维度, 而是综合利用全文内容进行判断, 并将其与量价数据和宏观研报相结合, 从而实现更丰富的数据多样性和更全面的交易信号生成.

3 研究方法

本文提出了一种基于大语言模型和多源数据的智能化投资决策支持系统, 主要由三个专业化的信息分析模块和一个综合决策的信号生成模块构成[2]. 其中, 信息分析模块分别负责特定领域的信息处理与总结, 信号生成模块则负责整合各领域信息, 输出最终的投资决策信号及相应的投资建议. 该系统基于阿里通义千问的 Qwen2.5 系列开源大语言模型 (Qwen et al., 2025) 和 GTE 系列文本向量模型 (Li et al., 2011) 构建. 四个模块在无记忆、无外部知识检索 (未使用 RAG) 的条件下独立运行, 仅依赖零样本提示完成任务, 并通过将模型温度系数设置为 0 来确保输出结果的可复现性和稳定性, 完整的提示词模板见附录[3].

3.1 新闻分析模块

作为市场信息的重要载体, 公司相关新闻不仅反映了自身的经营状况和发展动态, 还揭示了其上下游企业和行业竞争格局的变化趋势, 对市场情绪和股价波动具有显著影响. 新闻数据来源于多元化的信息渠道, 包括但不限于公司公开文件和公告、媒体动态报道、分析师意见和社交媒体消息等. 不同来源的新闻数据呈现出独特的特征: 公司公开文件和公告具有较高的可靠性和发布周期性, 媒体动态报道则表现出较强的时效性和传播性, 分析师意见往往具有专业性和一定滞后性, 而社交媒体消息则体现出多样性特点. 这些多维特征为新闻数据处理带来了诸多挑战, 主要体现在高时间敏感性、信息频率不一致、内容重复性以及低信噪比等方面. 本节构建了新闻分析模块, 该模块主要负责新闻数据的全流程处理, 包括新闻输入、逐篇总结、信息筛选以及月度总结生成等核心功能. 具体而言, 主要包含以下三个关键步骤:

[2]根据 Xiao et al. (2024), 智能体是指 “通过感知环境并采取行动以影响环境的任何实体”, 包括简单反射型 (simple reflex)、基于模型的反射型 (model-based reflex)、目标导向型 (goal-based) 和效用导向型 (utility-based) 智能体四类. 本文系统的各模块独立感知输入并依赖特定提示词规则选择行为, 无内部状态更新或目标规划, 故可视为简单反射型智能体. 感谢审稿专家对智能体概念说明和范围界定的意见.

[3]由于文本总结任务需要处理大量的 Token 输入, 若采用以 Token 计费的 API 调用方式, 其成本将远高于以时间计费的租用远程服务器部署方式. 因此, 本文选择远程服务器部署方案, 以降低系统运行成本. 硬件设备为 AMD EPYC 9754 十八核 CPU、60 GB 内存和 NVIDIA RTX 4090D (24GB) GPU. 本文旨在评估多源信息在最简单、最可控的条件下所能产生的投资价值, 因此采用当前的智能体设计即可实现研究目标, 也有助于更清晰地识别不同数据源本身所能贡献的增量信息.

中国知网 https://www.cnki.net

3.1.1 逐篇新闻总结

新闻分析模块通过匹配新闻主体表和公司标签表来获取面板新闻数据, 其中公司标签可以快速定位新闻相关公司, 而标签相关度则用于高效筛选与目标公司具有较高相关性的新闻 (本文设定相关度阈值为 0.5). 考虑到本文使用本地部署的小参数量 (7B) 模型, 为避免模型幻觉和受限于上下文长度, 在进行月度新闻总结之前, 需要预先对所有新闻进行单独的主题分类和逐篇总结. 主题分类标准参考 Fan et al. (2024) 的研究, 根据文本内容将新闻归类至与公司行为最相关的主题中, 具体主题类别包括: “财务表现” “运营业务” “公司治理” “人力资本” “社会责任” “环境责任” “风险管理” 和 “研发创新” 八类. 对于内容过于笼统的新闻, 则统一归类为 “其他”. 因此, 对于公司 s 的第 i 篇新闻原文 $\text{News}_{s,i}$, 通过 LLMs 实现单篇新闻总结的过程为:

$$(N_{s,i}, T_{s,i}) = \text{News_Sum_}i(\text{News}_{s,i}), \tag{1}$$

其中, $N_{s,i}$ 为公司 s 第 i 篇新闻的总结, $T_{s,i}$ 为公司 s 第 i 篇新闻的主题, News_Sum_i 为基于 LLMs 提示词设计的单篇新闻总结和分类函数.

3.1.2 去重处理

针对新闻数据的低信噪比特征, 在完成单篇主题分类和总结后, 还需要对相似度较高的新闻进行筛选, 以提升模型运行效率并降低因重复信息导致的模型偏误. 既有研究已从不同角度支持对高度相似文本进行剔除的必要性: 一方面, 新闻的新颖性被证明对市场行为具有重要影响, 高度重复的信息往往隐藏较少的增量信号 (Glasserman et al., 2023); 另一方面, 在大规模文本处理中, 适度去重有助于降低计算冗余并缓解模型对重复样本的过度拟合, 从而提升模型的泛化能力 (Lee et al., 2022).

为此, 本文借鉴已有文献的经典做法 (Ehrmann and Talmi, 2020; 张一帆等, 2022), 将文本向量之间较高的余弦相似度作为识别 “重复文本” 的经验判断标准. 具体剔除流程包括以下步骤: 首先, 使用 GTE 模型将 3.1.1 节得到的新闻总结文本转化为包含词语位置信息的文本向量. 其次, 计算每只股票每个月内所有新闻文本向量之间的余弦相似度矩阵, 量化新闻间的文本相似度. 最后, 设定相似度阈值为 0.8, 对相似度高于该阈值的新闻进行剔除, 仅保留具有异质性信息特征的新闻用于后续的月度新闻总结. 该阈值在实证上较好地平衡了信息保留的充分性与计算成本的控制, 兼顾了数据质量与运算效率, 并表现出较好的稳健性[4].

3.1.3 月度新闻总结

在完成上述新闻数据的预处理后, 每只股票经过剔除后的月度新闻已经被分类至不同主题中, 随后通过大语言模型提炼各个主题下的所有新闻并生成简洁的月度新闻总结. 其数学模型可表示为:

$$N_{s,m} = \bigcup_{t=1}^{9} \text{News_Sum}\left(\bigcup_{i \in m} N_{s,i}(T_{s,i} = t) \right), \tag{2}$$

[4]相关结果见附录. 感谢匿名审稿专家提出的宝贵建议.

中国知网 https://www.cnki.net

其中, $N_{s,m}$ 为公司 s 在 m 月的月度新闻总结, News_Sum 为月度新闻总结函数, $T_{s,i}$ 为新闻主题. 附录展示了新闻分析模块的月度总结示例.

3.2 股价分析模块

公司股价作为资本市场最直观的指标, 不仅体现了公司自身的价值创造能力和市场认可度, 其风险收益指标还能直观揭示公司与行业竞争者、市场整体表现之间的相对关系, 对投资者决策和资金流向具有重要的指导意义. 本节构建了股价分析模块, 其主要负责股价数据的全流程处理, 包括股价数据获取、风险收益指标构造、关联公司识别以及月度总结生成等核心功能. 具体而言, 主要包含以下三个关键步骤:

3.2.1 关联公司识别

为了全面分析目标公司的股价表现, 首先需要识别其关联公司, 包括同行业竞争者、上下游企业以及具有相似市场特征的公司, 参考 Vamvourellis et al. (2024) 的研究, 股价分析模块基于公司基本信息的文本使用嵌入大语言模型进行文本相似度识别. 具体识别流程包括以下步骤: 首先, 与新闻相似度剔除类似, 使用 GTE 将每只股票的公司基本信息文本转化为包含词语位置信息的文本向量. 其次, 计算所有公司基本信息文本向量之间的余弦相似度矩阵, 通过基本信息文本中的公司介绍、主营业务和基本信息等多维度信息, 量化公司之间的关联程度. 最后, 识别出与目标公司关联程度前五的公司作为关联公司用于后续分析. 这一过程不仅快速识别出了关联公司, 同时还避免了仅使用同行业公司或上下游公司作为关联公司的局限性.

3.2.2 风险收益指标表格

本文基于日度收盘价序列, 构建了覆盖长期 (过去一年、过去六个月) 与短期 (过去三个月、过去一个月) 的风险收益指标表格, 通过与关联公司及市场指数对比, 既衡量绝对表现, 也反映相对竞争地位, 为投资决策提供多维量化依据. 为将结构化表格有效输入大语言模型, 本文将数据转换为 Markdown 格式, 可以降低 Token 消耗, 提高模型输出效率, 从而为后续分析提供高效、兼容的数据输入方式. 附录提供了风险收益指标表格的相关示例.

3.2.3 月度股价总结

在对股价数据进行上述预处理后, 通过大语言模型提炼目标公司与关联公司及市场指数的风险收益指标表格, 并生成简洁的月度股价总结. 模型从多个维度对风险收益情况进行归纳和总结, 具体主题类别包括 “累计收益” “风险和波动性” “夏普比率” 和 “相关公司和市场的相关性”. 其数学模型可表示为:

$$P_{s,m} = \text{Price_Sum}\left(\text{Metrics}_{s,m}, \bigcup_{t=1}^{5} \text{Metrics}_{\text{peer}_i,m}, \text{Metrics}_{\text{index},m}\right), \tag{3}$$

其中, $P_{s,m}$ 为公司 s 在 m 月的月度股价总结, $\text{Metrics}_{s,m}$ 为目标公司 s 在 m 月的风险收益指标, $\text{Metrics}_{\text{peer}_i,m}$ 为关联公司 peer_i, $(i = 1, \cdots, 5)$ 在 m 月的风险收益指标, $\text{Metrics}_{\text{index},m}$ 为市场指数 index 在 m 月的风险收益指标, Price_Sum 为月度股价总结函数. 附录展示了股价分析模块的月度总结示例.

中国知网　https://www.cnki.net

3.3 宏观经济分析模块

宏观经济环境作为影响资本市场整体表现的核心因素, 不仅决定了行业发展的整体趋势, 还通过政策调整、经济周期波动以及市场预期变化等机制对个股表现产生深远影响. 鉴于宏观经济数据的多样性和专业性, 本文选用券商宏观经济研究报告作为基础分析数据. 本节构建了宏观经济分析模块, 其主要负责宏观经济数据的全流程处理, 包含以下两个关键步骤:

3.3.1 宏观经济研究报告

考虑到宏观经济研究报告在券商之间存在较高的同质化特征, 且头部券商的研究报告具有显著的权威性和市场影响力, 同时为了避免因报告数量过多而导致的分析成本, 本文选取每年新财富最佳分析师评选第一名的券商宏观经济团队发布的研究报告, 作为宏观经济分析的数据来源[5].

3.3.2 月度宏观经济总结

在完成研究报告筛选后, 利用大语言模型对月内权威分析师撰写的宏观经济研究报告进行深度分析和信息提炼, 从 “通货膨胀” “经济增长” “货币和财政政策” “国际贸易” 和 “投资机会” 五大主题维度, 生成简洁的月度宏观经济总结. 其数学模型可表示为:

$$M_m = \text{Macro_Sum}\left(\bigcup_{i \in m} \text{Report}_i\right), \tag{4}$$

其中, M_m 为 m 月的月度宏观经济总结, Report_i 为第 i 篇宏观经济研究报告的原文, Macro_Sum 为月度宏观经济总结函数. 附录提供了宏观经济分析模块的月度总结示例.

3.4 信号生成模块

作为整个系统的核心决策模块, 信号生成模块负责整合新闻分析、股价分析和宏观经济分析模块输出的月度总结信息, 生成最终的投资决策信号并提供全面投资建议. 具体而言, 主要包含以下两个关键功能:

3.4.1 月度投资决策信号与全面投资建议

首先, 对三个分析模块输出的总结文本进行整合, 从新闻总结中判断市场情绪, 从股价总结中分析股价趋势, 从宏观经济总结中评估宏观经济状况; 其次, 基于整合后的信息通过大语言模型生成投资决策信号 (买入、持有和卖出); 最后, 为每个信号提供简明扼要的投资建议, 包括决策依据、潜在风险和预期收益等. 其数学模型可表示为:

$$(\text{Signal}_{s,m}, \text{Explanation}_{s,m}) = \text{Signal_Gen}(N_{s,m}, P_{s,m}, M_m gna \tag{5}$$

其中, $\text{Signal}_{s,m} \in \{$买入, 持有, 卖出$\}$ 为公司 s 在 m 月的投资决策信号, $\text{Explanation}_{s,m}$ 为公司 s 在 m 月的全面投资建议, $N_{s,m}$ 为公司 s 在 m 月的月度新闻总结, $P_{s,m}$ 为公司 s 在 m 月的月度股价总结, M_m 为 m 月的月度宏观经济总结, Signal_Gen 为月度信号生成函数. 附录展示了信号生成模块的输出结果示例.

[5]在本文所研究的样本期间, 广发证券在宏观经济研究领域保持领先优势, 连续五年荣膺最佳分析师第一名.

中国知网 https://www.cnki.net

3.4.2 基于全面投资建议的买入评分

为了提升投资决策信号的有效性和可操作性, 本文进一步为买入信号构建了评分机制. 具体而言, 模块对全面投资建议文本进行深度解析, 输出 0∼10 的整数买入评分, 其中 0 代表建议谨慎买入, 10 代表建议强烈买入. 评分越低代表建议越谨慎, 越高代表建议越强烈. 评分机制不仅能够帮助投资者识别最具投资潜力的标的, 还提供了清晰的投资优先级, 有助于优化投资组合配置和最大化投资收益.

4 实证分析

4.1 数据说明

本文以 2020 年 1 月 1 日至 2024 年 12 月 31 日为样本期, 选取沪深 300 指数成份股作为研究对象, 共包括 459 只历史成份股. 一方面, 所选样本覆盖行业广泛、市场关注度高, 能够提供充足的数据量以反映多源信息对资产价格的影响. 另一方面, 该时期经历了疫情冲击、经济复苏及政策调整等关键阶段, 有利于评估模型在不同市场环境下的适应性. 考虑到 LLMs 的算力要求及多源数据处理的复杂性, 五年样本期在保证代表性的同时, 也兼顾了计算可行性.

新闻文本数据来源于数库科技 (ChinaScope) 的 SmarTag 新闻数据库. 该数据库全面覆盖全网财经、产业及政府披露的海量新闻报道, 并拥有公司、人物、事件、行业及产品等关键标签. 经过公司相关性筛选与文本相似度去重处理后, 最终样本涵盖 459 只股票在 60 个月内共 82.78 万篇新闻文本, 每只股票平均每月约 31 篇新闻, 每篇新闻的平均长度为 335 字.

公司基本信息文本来源于通联数据 (DataYes) 提供的上市企业基础信息数据库. 该数据集全面覆盖了 A 股市场所有上市公司的公司介绍、主营业务及基本信息等核心内容. 从样本特征来看, 企业信息文本长度存在显著异质性: 全样本平均字符数为 435 字, 最长的基本信息文本为 2858 字, 而最短仅为 23 字. 股票价格数据来自于万得 (Wind) 数据库提供的日度交易数据, 为确保数据的可比性与连续性, 采用前复权处理后的开盘价与收盘价. 经过数据清洗后, 共获得 353185 个股票-日度收益率观测值.

宏观经济研报数据来源于通联数据 (DataYes), 包括新财富最佳分析师评选数据和研究报告文本数据. 在经过多轮筛选后最终获得 869 份有效样本, 跨度覆盖全部样本期. 从统计结果来看, 研报数据表现出以下特征: 其一, 报告平均篇幅为 8.9 页, 其中摘要部分平均包含 2230 字符, 这一指标显著高于行业平均水平, 充分印证了宏观经济研究报告的理论深度与研究详实度; 其二, 从时间分布维度来看, 报告发布呈现出鲜明的季节性特征, 具体体现在各年度、季度国民经济运行情况发布的关键时点会出现显著的报告数量高峰.

4.2 大语言模型

本文主要将大语言模型用于中文文本总结和分析任务, 并不需要强大的推理能力, 同时出于运行成本和可复现性考虑选择开源模型. 因此, 最终选用 7B 指令微调模型 Qwen2.5-7B-Instruct 和 1.5B 参数量的文本向量模型 gte-Qwen2-1.5B-Instruct. 前者在自然语言理解、通用问答等方面表现超越了前代模型和同类模型 (如 Gemma2、Llama3.1 等)[6] , 后者同样优于

[6]资料来源: https://qwenlm.github.io/zh/blog/qwen2.5-llm/.

中国知网　https://www.cnki.net

同类模型 bge-large-en-1.5 (Xiao et al., 2024) 和 mxbai-embed-large-v1 (Li and Li, 2024). 稳健性检验部分则选取同一时期发布、参数规模相近且具备中文处理能力的模型进行对照, 包括中文训练充分的 GLM4-9B、以英文预训练为主但加入中文适配的 Llama3.1-8B-Chinese, 以及更大参数规模的 Qwen2.5-14B-Instruct[7].

4.3 投资决策信号投资组合分析

本节通过净值表现和风险收益特征检验大语言模型生成的投资决策信号对股票未来收益率的预测能力. 具体而言, 基于 “买入” “持有” 和 “卖出” 三种投资决策信号, 并以股票月度收盘价计算的收益率为基础, 对沪深 300 指数成份股分组构建等权和市值加权投资组合. 计算每个组合相对于沪深 300 指数的超额净值曲线和风险收益指标, 然后检验信号在选股表现上的准确性和单调性.

首先, 基于图 1 的等权投资组合超额净值曲线, 可以看出三类信号对应组合的策略表现呈现出清晰且稳定的梯度结构. “买入” 信号组合的超额净值曲线整体位于最上方, 并在样本期内呈上行趋势, 期末累计超额收益显著为正; 相比之下, “持有” 信号组合的净值曲线大部分时间围绕基准市场指数上下波动; “卖出” 信号组合的表现最弱, 其超额净值曲线长期处于最低水平, 且回撤幅度更大, 反映出明显的负向收益特征. 这一结果表明, 从绝对收益角度看, 模型生成的信号已能够有效区分未来收益的正负方向.

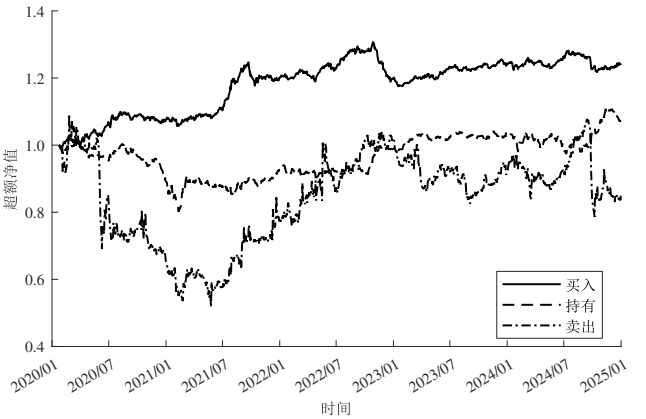


图 1 三类投资决策信号的投资组合超额净值曲线 (等权)

进一步地, 表 1 从多个维度展示了三类投资组合的风险收益情况. 以等权组合 (Panel A) 为例, 整体而言, 不同投资决策信号在收益与风险维度上呈现出显著差异. 1) 收益表现方面, 超额收益随信号由 “卖出” 向 “买入” 单调提升, 从 −15.08% 上升至 23.83%, 显示信号在横截面上具有较强的区分能力. 2) 风险特征方面, 随着信号积极程度提高, 年化波动显著下降 (由 27.90% 降至 5.40%). 3) 综合风险收益权衡来看, “买入” 组合的夏普比率最高 (0.85)、最大回撤较小 (−10.07%), 并且胜率最高 (55.60%); 而 “卖出” 组合则面临更大的下行风险和不利的风险暴露. 4) 策略稳定性方面, 三类组合的换手率整体处于中等水平, 说明策略并非高

[7]感谢匿名审稿专家提出补充大型语言模型稳健性检验的宝贵建议.

中国知网 https://www.cnki.net

表 1　三类投资决策信号的投资组合风险收益指标

投资决策信号	超额收益	年化收益	年化波动	夏普比率	最大回撤	胜率	换手率
Panel A: 等权							
买入	23.83%	4.61%	5.40%	0.85	−10.07%	55.60%	68.93%
持有	6.96%	1.43%	7.80%	0.18	−20.94%	47.83%	72.51%
卖出	−15.08%	−3.39%	27.90%	−0.12	−52.61%	49.00%	41.63%
Panel B: 市值加权							
买入	30.31%	5.74%	6.05%	0.95	−12.42%	55.35%	68.95%
持有	19.60%	3.84%	6.41%	0.60	−23.50%	51.51%	73.48%
卖出	12.23%	2.46%	28.48%	0.09	−52.65%	49.08%	36.84%

注: 表中的第一列报告了每组相对于沪深 300 指数的累计超额收益; 第二列到第四列分别报告了年化收益、年化波动以及夏普比率; 第五列报告了最大回撤, 定义为峰值到后期谷值下降幅度的最大值; 第六列报告了胜率, 定义为投资组合收益大于基准指数收益的比例; 第七列报告了换手率, 定义为每月成份股权重变化的绝对值之和的平均, 即 $\frac{1}{T}\sum_{t=1}^{T}(\frac{1}{2}\sum_i |w_{i,t+1} - \frac{w_{i,t}(1+r_{i,t})}{\sum_j w_{j,t}(1+r_{j,t})}|)$, 其中 $w_{i,t}$ 表示股票 i 在 t 月的权重, $r_{i,t}$ 表示股票 i 在 t 月的收益, 下同.

度依赖频繁调仓, 其中 “卖出” 组合换手率相对较低, 反映其持仓调整更为缓慢. 对于市值加权 (Panel B) 组合而言, 总体结论与等权组合一致: “买入” 信号在超额收益、夏普比率以及回撤控制等方面仍然占优[8].

4.4 买入评分排序投资组合分析

本节通过引入买入评分指标, 构建了等权和市值加权两种投资组合, 进一步检验 “买入” 信号的预测能力. 买入评分分布显示, 样本评分大量集中于 8 分 (占 87.70%). 因此, 选取 8 分作为阈值, 每月对沪深 300 指数成份股中的 “买入” 信号股票进行分组, 分别构建高评分多头 (做多评分 > 8) 和低评分空头 (做空评分 ≤ 8) 投资组合, 然后在每组中计算相对于沪深 300 指数的超额风险收益指标.

表 2 展示了等权和市值加权的四个多头和空头投资组合结果, 结果揭示了两个重要的研究发现. 第一, 市值加权投资组合较等权组合展现出相对优越的收益表现, 但同时也面临更大的风险敞口. 以多头策略为例, 市值加权下的超额收益达到 99.20%, 高于等权组合的 89.98%, 显示出在买入评分排序框架下, 大市值股票对组合收益贡献更为显著. 然而, 这种收益优势是以更大的下行风险为代价的: 市值加权多头组合的最大回撤为 −28.26%, 相比等权组合扩大了约 3.65%, 反映出权重向头部股票集中后, 组合对系统性冲击和市场调整的敏感性更强. 尽管如此, 两种加权方式下的夏普比率几乎一致 (均为 0.65), 且换手率差异较小, 说明收益提升在一定程度上被风险同步放大所抵消, 整体风险调整后绩效并未发生实质性改变.

[8] 与等权组合不同的是, “卖出” 组合在市值加权下仍然实现了正的超额收益. 这一现象并不必然意味着 “卖出” 信号本身具有正向预测能力, 而更可能源于样本结构因素: 对信号占比的统计分析表明, 由于沪深 300 成分股整体质量较高, “卖出” 信号在样本中所占比例显著低于 “买入” 信号, 市值加权下头部优质公司的权重较高, 从而在一定程度上弱化了负向信号的收益表现. 为避免该数据不平衡问题, 本文在下一节通过买入评分指标对 “买入” 信号进行更细致的分析.

中国知网　https://www.cnki.net

表 2 买入评分排序的投资组合风险收益指标

投资决策信号	超额收益	年化收益	年化波动	夏普比率	最大回撤	胜率	换手率
Panel A: 等权							
多头	89.98%	14.48%	22.11%	0.65	−24.61%	50.50%	44.99%
空头	19.18%	3.77%	5.57%	0.68	−10.23%	55.27%	91.79%
Panel B: 市值加权							
多头	99.20%	15.63%	24.01%	0.65	−28.26%	50.67%	41.16%
空头	27.39%	5.23%	6.39%	0.82	−14.68%	55.35%	91.85%

第二, 无论在等权还是市值加权框架下, 基于买入评分构建的多头与空头投资组合均实现了正向超额收益, 但多头策略的表现显著优于空头策略. 例如, 等权多头策略的超额收益为89.98%, 明显高于空头策略的 19.18%. 这一结果首先源于样本构造本身: 多头与空头策略均来自 “买入” 信号股票池, 空头并非对基本面或情绪极度悲观的股票进行做空, 而更多体现为相对弱势的买入信号分组, 因此其收益并未转为负值. 其次, 多头策略天然暴露于市场风险溢价, 在整体市场向上的样本区间内更容易获得额外回报; 相比之下, 空头策略在承担做空成本和机会成本的同时, 其收益上限也受到限制.

4.5 基于大语言模型的指数增强策略

本节基于买入评分排序的多头投资组合, 构建了沪深 300 指数增强策略. 策略基于实际投资场景出发, 在充分考虑交易成本和滑点等实际影响因素下进行评估. 具体回测参数设置为: 1) 调仓周期为 1 个月; 2) 股票池为剔除交易日停牌后的沪深 300 指数成份股; 3) 多头组合设定为买入评分大于 8 的股票; 4) 加权方式分别为等权和市值加权; 5) 对冲方案为沪深 300 指数对冲; 6) 回测期为 2020 年 1 月至 2024 年 12 月; 7) 收益率计算采用开盘价; 8) 考虑交易成本为单边 0.1% 至 0.3%. 图 2 显示, 在考虑交易成本 (0.1%) 和调整收益率计算方法后, 沪深 300 指数增强策略的超额净值整体呈现持续上行趋势, 期间虽伴随阶段性回撤, 但随后能够逐步修复, 体现出较好的长期增值能力与风险承担特征.

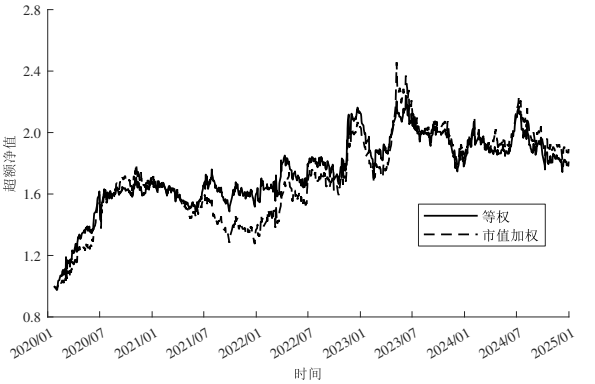


图 2 沪深 300 指数增强策略超额净值曲线

中国知网 https://www.cnki.net

表 3 进一步考察了在不同交易成本假设下, 沪深 300 指数增强策略的风险收益表现. 总体来看, 随着交易成本由 0.1% 逐步上升至 0.3%, 等权和市值加权投资组合的累计超额收益和年化收益均有所下降, 但策略仍保持稳定的正向收益, 显示出较强的成本稳健性. 在交易成本为 0.1% 时, 等权和市值加权组合的超额收益分别为 81.16% 和 89.55%, 夏普比率接近 0.60; 即便在交易成本提高至 0.3% 的情形下, 两类组合的夏普比率仍维持在 0.37 至 0.38 之间, 胜率稳定在 50% 左右. 上述结果表明, 基于买入评分排序构建的指数增强策略在考虑现实交易摩擦后依然具备可实施性和实践价值.

表 3　沪深 300 指数增强策略的风险收益指标

投资决策信号	超额收益	年化收益	年化波动	夏普比率	最大回撤	胜率	换手率
Panel A: 交易成本 = 0.1%							
等权	81.16%	13.34%	22.78%	0.59	−22.23%	50.67%	44.99%
市值加权	89.55%	14.42%	24.81%	0.58	−29.03%	50.50%	89.55%
Panel B: 交易成本 = 0.2%							
等权	63.44%	10.91%	22.83%	0.48	−24.72%	50.59%	44.99%
市值加权	71.01%	11.97%	24.84%	0.48	−30.71%	50.25%	41.16%
Panel C: 交易成本 = 0.3%							
等权	47.42%	8.52%	22.89%	0.37	−27.14%	50.25%	44.99%
市值加权	54.26%	9.56%	24.89%	0.38	−32.35%	50.08%	41.16%

4.6 多源数据的重要性分析与消融实验

为系统刻画投资决策信号在生成过程中对不同信息来源的依赖程度, 本文首先从文本相似度角度量化全面投资建议文本与新闻总结、股价总结以及宏观经济总结之间的关联性. 采用 GTE 模型的量化结果如表 4 所示, 全面投资建议与新闻总结和股价总结的平均相似度分别为 0.65 和 0.57, 显著高于其与宏观经济总结的相似度 (0.43). 这一差异表明, 模型在形成投资决策信号时, 更加侧重于反映企业与市场短期变化的高频信息, 尤其是最新新闻事件与价格动态所蕴含的即时信号, 从而强化了其在短期和月度预测中的市场响应能力. 相比之下, 宏观经济信息覆盖面更广、更新频率较低, 其对短期投资决策的影响相对温和.

在此基础上, 本文进一步设计了多源数据的消融实验, 以考察上述相关性结论在投资绩效层面的实际影响. 具体做法是依次剔除新闻总结、股价总结和宏观经济总结文本, 通过控制输入信息集合, 评估不同数据源对投资决策信号与买入评分生成效果的影响, 详细结果见附录. 我们发现, 消融实验的数据重要性排序与文本相似度分析结论一致. 在剔除新闻或股

表 4　全面投资建议与总结文本相似度统计

	均值	中位数	标准差	最小值	最大值
新闻总结	0.65	0.65	0.06	0.27	0.88
股价总结	0.57	0.57	0.05	0.29	0.82
宏观经济总结	0.43	0.43	0.05	0.12	0.63

中国知网　https://www.cnki.net

价总结后, 买入评分排序的投资组合的多头收益与空头收益出现倒置现象, 空头组合呈现正收益且显著高于多头组合的负收益, 这一结果凸显了新闻和股价数据对维持投资策略稳定性的关键作用. 相比之下, 剔除宏观经济信息导致整体收益水平和夏普比率有所降低, 但投资策略仍能保持 “买入评分越高则收益率越高” 的基本规律, 表明宏观经济信息的影响相对有限.

4.7 稳健性检验

为检验买入评分指标及相关实证结论的可靠性, 本文从样本筛选、信息处理规则和模型设定三个层面开展了一系列稳健性检验, 相关结果见附录. 在样本层面, 本文剔除了新闻覆盖不足和券商类股票样本[9]. 结果显示, 在剔除市场关注度较低的样本后, 等权投资组合在累计收益和夏普比率上均出现明显改善, 而市值加权组合的累计收益虽有所回落, 但夏普比率基本保持不变. 进一步剔除券商类股票样本后, 无论是等权投资组合还是市值加权投资组合, 其收益率均获得了一定程度的提高. 进一步地, 在文本处理层面, 本文对新闻文本去重过程中相似度阈值设定进行了稳健性检验. 正文基准情形采用 0.8 作为默认阈值, 同时将阈值调整为更宽松 (0.7) 和更严格 (0.9) 进行替代性测试, 并重新生成月度新闻摘要与对应的投资信号. 结果表明, 不同阈值下各类投资决策信号的相对收益排序和风险特征保持一致, 说明结论并不依赖于特定的参数取值. 最后, 在模型层面, 本文比较了不同大语言模型下的投资表现. 整体来看, 有两点规律较为明显: 第一, 不同模型的主要影响体现在收益水平与风险暴露的差异上, 而投资信号的方向性在大多数模型下保持一致, 强调了方法论本身的稳定性; 第二, 模型预训练语料与参数规模会显著影响性能边界, 中文训练更充分且参数规模更大的模型通常能提升策略收益上限, 但也可能带来更高波动或更频繁的交易.

5 金融数据微调大语言模型

5.1 金融语料数据

本文选用 A 股非沪深 300 指数历史成份股的个股深度研究报告作为金融语料数据, 进行大语言模型微调. 在股票二级市场中, 证券分析师收集、分析和传播有关上市公司未来前景的信息, 在投资者中承担着重要的信息中介和监控职能 (Asquith et al., 2005; Ali and Hirshleifer, 2020; Kumar et al., 2022). 鉴于研究报告文本与微调中标准问答语料的格式差异, 本文采用两种数据格式对 Qwen2.5-7B-Instruct 进行微调: 一是直接使用研究报告文本进行无监督预训练微调, 二是基于大语言模型处理的单轮问答数据集进行有监督微调.

5.1.1 样本筛选

与宏观经济研究报告的筛选标准类似, 本文基于新财富最佳分析师评选结果, 挑选各研究领域的权威深度研究报告作为微调金融语料. 考虑到不同券商关注个股存在差异, 本文选取 2020–2024 年每个研究领域前五名券商团队发布的深度报告, 并剔除所有涉及沪深 300 历史成份股的内容以避免样本内偏误. 进一步剔除 “宏观经济” “策略研究” “固定收益研究” “金融工程” 和 “港股及海外市场研究” 专题后, 共涵盖 25 个微观研究领域, 包括全部申万一

[9]为了确保研究样本的新闻数据充分性, 本文设定样本筛选标准为新闻量 $\geq$10, 样本有效观测值数量从 353185 个减少至 291264 个, 样本剔除率为 17.53%. 对于剔除券商类股票样本而言样本有效观测值数量从 353185 个缩减至 327861 个, 剔除了 7.17% 的样本.

中国知网 https://www.cnki.net

级行业, 最终获得 2535 篇报告.

5.1.2 单轮问答数据集

为了将研究报告文本转化为适合微调的单轮问答对格式, 本文参考九方智投发布的由专家分析师编写的 Stocksis 训练对 (Han et al., 2025), 结合思维链提示方法 (Wei et al., 2022) 提取报告中的关键信息, 生成标准化的问答对. 在附录中展示的示例中, “问” 部分保留了个股的背景信息, 包括运营指标、财务指标及量价指标等; “答” 部分则有效整合这些信息, 不仅提供评级与目标价, 还简要说明各类指标对评级的支撑作用, 实现了对研究报告核心内容的浓缩与结构化呈现.

5.2 大语言模型微调框架

高效微调对于将大语言模型应用于下游任务至关重要, 本文选用集成了多种前沿高效训练方法的大语言模型微调框架 Llama-Factory (Zheng et al., 2024). 该框架简化了常用的训练方法, 包括生成式预训练、监督式微调 (SFT)、基于人类反馈的强化学习 (RLHF) 以及直接偏好优化 (DPO), 并可通过 LLAMABOARD 网页界面实现低代码微调. 已有大量研究使用该框架对大语言模型进行训练并探索其下游应用 (Wang et al., 2023; Yu et al., 2023). 预训练微调和单轮问答微调均采用低秩适应 (LoRA) 微调方法 (Hu et al., 2023), 分别采用生成式预训练和监督式微调的训练方法, 训练参数保持相同[10].

5.3 实验结果

为评估金融语料微调对大语言模型投资决策能力的提升效果, 本节沿用基准实验中的净值表现和风险收益特征作为评价标准. 鉴于运行成本及语料特点, 本文保持数据处理的三类模板总结文本输出不变, 仅对信号生成模块进行金融知识微调, 以更精确地捕捉微调在投资信号判断上带来的边际改进效应.

如表 5 的 Panel A 所示, 经过无监督预训练微调后, 大语言模型在投资决策信号分档上的预测能力显著增强. 以等权组合为例, “买入” 与 “卖出” 组合的累计收益差从原先的 38.91% (= 23.83% + 15.08%) 提升至 53.96% (= 35.90% + 18.06%); “持有” 与 “卖出” 组合在收益与风险控制方面均优于基准结果, 胜率和换手率亦有所改善. 这表明预训练微调初步增强了模型对金融市场信号的敏感性, 提高了其作为量化投资工具的实际效能. 此外, 微调后的模型解决了市值加权组合中 “卖出” 信号收益为正的问题, 使多空策略收益与风险特征更加符合预期. 进一步地, Panel B 的结果表明, 引入单轮问答数据集的监督式微调后, 模型性能进一步提升. 等权 “买入” 与 “卖出” 组合间的累计收益差提升至 59.45% (= 30.79% + 28.66%), 显示监督信息显著优化了模型的投资判断. 整体来看, 监督微调有助于将专业知识注入模型, 有效放大其对市场信息的响应幅度, 提升策略收益表现.

[10]默认的核心训练参数选择为: 1) 学习率为 5×10^{-5}; 2) 训练轮数为 6 轮; 3) 最大梯度范数为 1; 4) 最大样本数为 100000; 5) 计算类型为 bf16; 6) 截断长度为 1024; 7) 批处理大小为 2; 8) 梯度累积步数为 8; 9) 学习率调节器为 cosine, 均参考已有研究的标准设定以保证微调效果与可复现性.

中国知网 https://www.cnki.net

表 5 金融知识增强后三类投资决策信号的投资组合风险收益指标

投资决策信号	超额收益	年化收益	年化波动	夏普比率	最大回撤	胜率	换手率
Panel A: 预训练微调							
买入 (等权)	35.90%	6.68%	10.78%	0.62	−17.20%	51.76%	55.13%
持有 (等权)	13.74%	2.75%	5.14%	0.54	−13.07%	50.42%	92.49%
卖出 (等权)	−18.06%	−4.11%	21.04%	−0.20	−41.14%	50.25%	88.88%
买入 (市值)	40.27%	7.39%	12.82%	0.58	−21.18%	51.42%	55.13%
持有 (市值)	25.60%	4.92%	3.31%	1.48	−5.82%	56.77%	91.46%
卖出 (市值)	−18.06%	−4.11%	21.04%	−0.20	−41.14%	50.25%	89.17%
Panel B: 单轮问答微调							
买入 (等权)	30.79%	5.82%	8.42%	0.69	−15.39%	55.02%	89.53%
持有 (等权)	11.13%	2.25%	6.28%	0.36	−18.64%	49.41%	84.96%
卖出 (等权)	−28.66%	−6.87%	26.61%	−0.26	−58.19%	46.91%	65.00%
买入 (市值)	36.10%	6.71%	9.41%	0.71	−21.29%	53.43%	89.57%
持有 (市值)	17.69%	3.49%	5.24%	0.67	−19.81%	52.93%	81.83%
卖出 (市值)	−13.82%	−3.09%	26.84%	−0.11	−55.00%	47.07%	60.36%

6 结论与启示

通过模块化智能体架构设计、多领域数据融合以及金融知识增强微调技术, 本文提出的智能化决策支持系统不仅验证了大语言模型在金融文本分析中的有效性, 还构建了具有实践价值的指数增强策略, 为市场分析和投资决策提供了新的解决方案. 智能化决策支持系统由新闻分析、股价分析、宏观经济分析及信号生成四个模块构成, 各模块之间独立运行且功能解耦. 实证结果表明, 基于大语言模型的智能化决策支持系统能够有效整合新闻、股价和宏观经济等多维度信息, 生成具有显著预测能力的投资决策信号和买入评分. 进一步地, 利用券商深度研究报告微调后的大语言模型展示出了更强的投资决策信号分档预测能力.

基于上述研究发现, 本文提出以下政策建议: 第一, 构建高质量、可共享的金融微调语料库, 推动人工智能技术在金融领域的应用. 当前, 大语言模型在金融领域的应用仍处于初级阶段, 缺乏专门针对金融语境的高质量训练数据. 建议监管机构和行业协会牵头, 整合券商研究报告、财经新闻、公司公告等多源数据, 构建标准化、高质量的金融语料库, 支持科研机构和市场参与者开展模型训练与优化. 第二, 制定针对智能投资决策系统的透明度和可解释性标准. 随着人工智能技术的深度应用, 算法黑箱问题日益凸显. 为此, 应建立完整的 “人工智能 + 金融” 的披露制度, 要求机构投资者在使用智能投顾或算法交易系统时, 充分披露模型的决策逻辑、数据来源和风险特征, 保障投资者的知情权和选择权, 维护市场公平与稳定. 第三, 加强对中小投资者的教育和保护, 促进智能投顾服务的普惠发展. 大语言模型等 AI 技术不仅能够服务机构投资者, 也能够通过智能投顾等形式帮助个人投资者提升决策质量, 降低非理性交易行为. 建议监管部门在规范行业发展的同时, 鼓励金融机构开发适用于个人投资者的智能投顾工具, 推动金融信息服务的智能化升级, 实现金融科技发展成果的更广泛共享.

中国知网 https://www.cnki.net

未来研究可从以下方向深入推进: 首先, 可联合训练中英文的 A 股、港股及美股数据, 提取跨市场共性特征, 构建全球化资产配置模型, 提升智能投资决策系统的多语言与跨市场泛化能力. 其次, 应构建高质量金融微调语料库, 结合深度学习等前沿训练方法进一步增强大语言模型的金融知识, 从而在更大样本规模和更长时间跨度下检验模型的泛化性与稳健性. 最后, 可探索模型可解释性、人机协同决策及提示词设计对策略稳定性的影响, 以深化对大语言模型在投资决策及其他经济行为中的内在机制理解.

参　考　文　献

程兵, (2023). 以 ChatGPT 为代表的大语言模型打开了经济学和其他社会科学研究范式的巨大新空间 [J]. 计量经济学报, 3(3): 589–614.

Cheng B, (2023). Artificial Intelligence Generative Content (AIGC) Including ChatGPT Opens a New Big Paradigm Space of Economics and Social Science Research[J]. China Journal of Econometrics, 3(3): 589–614.

何勇, 焦丽, 杨艺, 祝怡菲, (2024). AI 大模型赋能金融市场量化投资? 基于另类数据与传统金融数据的研究 [J]. 计量经济学报, 4(3): 761–783.

He Y, Jiao L, Yang Y, Zhu Y F, (2024). AI Large Language Model Empowers Quantitative Investment in Financial Markets? Research Based on Alternative Data and Traditional Financial Data[J]. China Journal of Econometrics, 4(3): 761–783.

何勇, 李琪琪, 焦丽, 黄文萱, (2023). 另类数据在中国股票市场投资中有用吗? —— 基于财经短视频、图像、文本数据的探究 [J]. 计量经济学报, 3(4): 1008–1031.

He Y, Li Q Q, Jiao L, Huang W X, (2023). Is Alternative Data Useful in China Share Market Investment? — Empirical Study Based on Financial Short Video, Image and Text Data[J]. China Journal of Econometrics, 3(4): 1008–1031.

何勇, 杨艺, 陈妍, 胡明珠, (2025). AI 智能体能否成为智能投顾新助手?[J]. 计量经济学报, 5(3): 818–841.

He Y, Yang Y, Chen Y, Hu M Z, (2025). Can AI Agent be the New Assistant to Robo-advisers?[J]. China Journal of Econometrics, 5(3): 818–841.

洪永淼, 汪寿阳, (2024). ChatGPT 与大模型将对经济学研究范式产生什么影响?[J]. 计量经济学报, 4(1): 1–25.

Hong Y M, Wang S Y, (2024). How Will ChatGPT and Large Models Influence the Research Paradigm in Economics?[J]. China Journal of Econometrics, 4(1): 1–25.

姜富伟, 刘雨旻, 孟令超, (2024). 大语言模型、文本情绪与金融市场 [J]. 管理世界, 40(8): 42–64.

Jiang F W, Liu Y M, Meng L C, (2024). Large Language Model and Textual Sentiment Analysis in Chinese Stock Markets[J]. Journal of Management World, 40(8): 42–64.

姜富伟, 孟令超, 唐国豪, (2021). 媒体文本情绪与股票回报预测 [J]. 经济学 (季刊), 21(4): 1323–1344.

Jiang F W, Meng L C, Tang G H, (2021). Media Textual Sentiment and Chinese Stock Return Predictability[J]. China Economic Quarterly, 21(4): 1323–1344.

廖理, 崔向博, 孙琼, (2021). 另类数据的信息含量研究——来自电商销售的证据 [J]. 管理世界, 37(9): 90–104.

Liao L, Cui X B, Sun Q, (2021). The Information Content of Alternative Data: Evidence from E-commerce Sales[J]. Journal of Management World, 37(9): 90–104.

林建浩, 陈良源, 罗子豪, 张一帆, (2021). 央行沟通有助于改善宏观经济预测吗? —— 基于文本数据的高维

中国知网　https://www.cnki.net

稀疏建模 [J]. 经济研究, 56(3): 48–64.

Lin J H, Chen L Y, Luo Z H, Zhang Y F, (2021). Does Central Bank Communication Improve Macroeconomic Forecasting? — High-dimensional Sparse Modeling Based on Text Data[J]. Economic Research Journal, 56(3): 48–64.

林建浩, 孙乐轩, (2025). 大语言模型与经济金融文本分析: 基本原理、应用场景与研究展望 [J]. 计量经济学报, 5(1): 1–34.

Lin J H, Sun L X, (2025). Text Analysis in Economics and Finance with Large Language Models: Fundamentals, Applications, and Future Prospects[J]. China Journal of Econometrics, 5(1): 1–34.

林建浩, 张一帆, 陈良源, 邓益萌, (2022). 基于新闻情绪的机器学习交易策略 [J]. 计量经济学报, 2(4): 881–908.

Lin J H, Zhang Y F, Chen L Y, Deng Y M, (2022). News Sentiment and Machine Learning Investment Strategy[J]. China Journal of Econometrics, 2(4): 881–908.

游家兴, 吴静, (2012). 沉默的螺旋: 媒体情绪与资产误定价 [J]. 经济研究, 47(7): 141–152.

You J X, Wu J, (2012). Spiral of Silence: Media Sentiment and the Asset Mispricing[J]. Economic Research Journal, 47(7): 141–152.

张一帆, 林建浩, 杨扬, 邓益萌, (2022). 央行沟通、信息冲击与国债市场波动 [J]. 系统工程理论与实践, 42(3): 575–590.

Zhang Y F, Lin J H, Yang Y, Deng Y M, (2022). Central Bank Communication, Information Shock and Treasury Market Volatility[J]. Systems Engineering — Theory & Practice, 42(3): 575–590.

Aleti S, Bollerslev T, (2025). News and Asset Pricing: A High-Frequency Anatomy of the SDF[J]. The Review of Financial Studies, 38(3): 712–759.

Ali U, Hirshleifer D, (2020). Shared Analyst Coverage: Unifying Momentum Spillover Effects[J]. Journal of Financial Economics, 136(3): 649–675.

Alqahtani A, Wither M J, Dong Z, Goodwin K R, (2020). Impact of News-based Equity Market Volatility on International Stock Markets[J]. Journal of Applied Economics, 23(1): 224–234.

Antweiler W, Frank M Z, (2004). Is All that Talk Just Noise? The Information Content of Internet Stock Message Boards[J]. The Journal of Finance, 59(3): 1259–1294.

Asquith P, Mikhail M B, Au A S, (2005). Information Content of Equity Analyst Reports[J]. Journal of Financial Economics, 75(2): 245–282.

Bastianello F, Décaire P H, Guenzel M, (2024). Mental Models and Financial Forecasts[EB/OL]. [2025-11-22]. https://westernfinance-portal.org/viewpaper?n=1012900.

Brown T B, Mann B, Ryder N, Subbiah M, Kaplan J, et al. (2020). Language Models are Few-shot Learners[EB/OL]. [2026-01-12]. http://arxiv.org/abs/2005.14165.

Bybee L, Kelly B, Su Y, (2023). Narrative Asset Pricing: Interpretable Systematic Risk Factors from News Text[J]. The Review of Financial Studies, 36(12): 4759–4787.

Cao S S, Jiang W, Lei L G, Zhou Q C, (2024). Applied AI for Finance and Accounting: Alternative Data and Opportunities[J]. Pacific-Basin Finance Journal, 84: 102307.

Ehrmann M, Talmi J, (2020). Starting from a Blank Page? Semantic Similarity in Central Bank Communication and Market Volatility[J]. Journal of Monetary Economics, 111: 48–62.

Fan J, Liu Q, Song Y, Wang Z, (2024). Measuring Misinformation in Financial Markets[EB/OL]. [2025-03-05]. https://papers.ssrn.com/abstract=4922648.

Glasserman P, Mamaysky H, Qin J, (2023). New News is Bad News[EB/OL]. [2025-11-24]. http://arxiv.org/abs/2309.05560.

中国知网 https://www.cnki.net

Han S, Zhou C, Shen Y, Sun Y, Zhou Y, et al. (2025). Finsphere: A Conversational Stock Analysis Agent Equipped with Quantitative Tools Based on Real-Time Database[EB/OL]. [2025-03-17]. http://arxiv.org/abs/2501.12399.

Hu A, Ma S, (2025). Persuading Investors: A Video-based Study[J]. The Journal of Finance, 80(5): 2639–2688.

Hu E J, Wallis P, Allen-Zhu Z, Li Y, Wang S, et al. (2022). Lora: Low-rank Adaptation of Large Language Models[C/OL]// International Conference on Learning Representations. [2025-03-31]. https://openreview.net/forum?id=nZeVKeeFYf9.

Jiang J, Kelly B, Xiu D, (2023). (Re-) Imag (in) Ing Price Trends[J]. The Journal of Finance, 78(6): 3193–3249.

Ke Z T, Kelly B T, Xiu D, (2020). Predicting Returns with Text Data[EB/OL]. [2025-03-14]. https://papers.ssrn.com/abstract=3389884.

Kim A G, Nikolaev V V, (2024). Context-based Interpretation of Financial Information[J/OL]. Journal of Accounting Research, [2026-01-19]. https://doi.org/10.1111/1475-679X.12593.

Kumar A, Rantala V, Xu R, (2022). Social Learning and Analyst Behavior[J]. Journal of Financial Economics, 143(1): 434–461.

Lee J, Stevens N, Han S C, (2025). Large Language Models in Finance (FinLLMs)[J]. Neural Computing and Applications, 37: 24853–24867.

Lee K, Ippolito D, Nystrom A, Zhang C, Carlini N, (2022). Deduplicating Training Data Makes Language Models Better[EB/OL]. [2025-11-24]. http://arxiv.org/abs/2107.06499.

Li X M, Li J, (2024). Angle-optimized Text Embeddings[EB/OL]. [2025-03-22]. http://arxiv.org/abs/2309.12871.

Li X, Li Z, Shi C, Xu Y, Du Q, et al. (2024). Alphafin: Benchmarking Financial Analysis with Retrieval-Augmented Stock-Chain Framework[C/OL]// Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024). 773–783[2025-03-17]. https://aclanthology.org/2024.lrec-main.69/.

Li Y, Yu Y, Li H, Chen Z, Khashanah K, (2023). Tradinggpt: Multi-agent System with Layered Memory and Distinct Characters for Enhanced Financial Trading Performance[EB/OL]. [2025-03-17]. http://arxiv.org/abs/2309.03736.

Li Z H, Zhang X, Zhang Y Z, Long D K, Xie P J, et al. (2023). Towards General Text Embeddings with Multi-Stage Contrastive Learning[EB/OL]. [2025-03-05]. http://arxiv.org/abs/2308.03281.

Loughran T, Mcdonald B, (2011). When is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks[J]. The Journal of Finance, 66(1): 35–65.

Nie Y, Kong Y, Dong X, Mulvey J M, Poor H V, et al. (2024). A Survey of Large Language Models for Financial Applications: Progress, Prospects and Challenges[EB/OL]. [2025-03-05]. http://arxiv.org/abs/2406.11903.

Qwen, Yang A, Yang B, Zhang B, Hui B, et al. (2025). Qwen2.5 Technical Report[EB/OL]. [2025-03-04]. http://arxiv.org/abs/2412.15115.

Russell S, Norvig P. (2020). Artificial Intelligence: A Modern Approach[M]. 4th ed.

Shiller R J, (2017). Narrative Economics[J]. American Economic Review, 107(4): 967–1004.

Sun Y, Liu L, Xu Y, Zeng X, Shi Y, et al. (2024). Alternative Data in Finance and Business: Emerging Applications and Theory Analysis (Review)[J]. Financial Innovation, 10(1): 127.

中国知网　https://www.cnki.net

Tetlock P C, Saar-Tsechansky M, Macskassy S, (2008). More Than Words: Quantifying Language to Measure Firms' Fundamentals[J]. The Journal of Finance, 63(3): 1437–1467.

Vamvourellis D, Tóth M, Bhagat S, Desai D, Mehta D, et al. (2024). Company Similarity Using Large Language Models[C/OL]// 2024 IEEE Symposium on Computational Intelligence for Financial Engineering and Economics (CIFEr). 1–9[2025-03-17]. https://ieeexplore.ieee.org/abstract/document/10772990.

Wang L, Lyu C, Ji T, Zhang Z, Yu D, et al. (2023). Document-level Machine Translation with Large Language Models[C/OL]// Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 16646–16661[2025-03-31]. https://aclanthology.org/2023.emnlp-main.1036/.

Wang S, Yuan H, Ni L M, Guo J, (2024). Quantagent: Seeking Holy Grail in Trading by Self-Improving Large Language Model[EB/OL]. [2025-03-20]. http://arxiv.org/abs/2402.03755.

Wang S, Yuan H, Zhou L, Ni L, Shum H, et al. (2023). Alpha-gpt: Human-ai Interactive Alpha Mining for Quantitative Investment[EB/OL]. [2025-03-17]. http://arxiv.org/abs/2308.00016.

Wei J, Wang X, Schuurmans D, Bosma M, Ichter B, et al. (2022). Chain-of-thought Prompting Elicits Reasoning in Large Language Models[J]. Advances in Neural Information Processing Systems, 35: 24824–24837.

Xiao S, Liu Z, Zhang P, Muennighof N, Lian D, et al. (2024). C-pack: Packed Resources for General Chinese Embeddings[EB/OL]. [2025-03-22]. http://arxiv.org/abs/2309.07597.

Xiao Y, Sun E, Luo D, Wang W, (2025). Tradingagents: Multi-agents LLM Financial Trading Framework[EB/OL]. [2025-03-17]. http://arxiv.org/abs/2412.20138.

Yang H, Zhang B, Wang N, Guo C, Zhang X, et al. (2024). Finrobot: An Open-Source AI Agent Platform for Financial Applications Using Large Language Models[EB/OL]. [2025-03-05]. http://arxiv.org/abs/2405.14767.

Yu H, Yang Z, Pelrine K, Godbout J F, Rabbany R, (2023). Open, Closed, or Small Language Models for Text Classification?[EB/OL]. [2025-03-31]. http://arxiv.org/abs/2308.10092.

Yu Y, Li H, Chen Z, Jiang Y, Li Y, et al. (2024). Finmem: A Performance-enhanced LLM Trading Agent with Layered Memory and Character Design[J]. Proceedings of the AAAI Symposium Series, 3(1): 595–597.

Yuan H, Wang S, Guo J, (2024). Alpha-gpt 2.0: Human-in-the-loop AI for Quantitative Investment[EB/OL]. [2025-03-17]. http://arxiv.org/abs/2402.09746.

Zarifhonarvar A, (2026). Generating Inflation Expectations with Large Language Models[J]. Journal of Monetary Economics, 157: 103859.

Zheng Y, Zhang R, Zhang J, Ye Y, Luo Z, et al. (2024). Llamafactory: Unified Efficient Fine-Tuning of 100+ Language Models[C/OL]// Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations). Bangkok, Thailand: Association for Computational Linguistics: 400–410[2025-03-30]. https://aclanthology.org/2024.acl-demos.38/.

中国知网 https://www.cnki.net