我国上市公司创新活动的测度*

——基于文本分析的方法

谢佳松　樊嘉诚　林建浩

内容提要：现有文献主要基于专利或研发投入测度企业创新水平进行实证分析，然而专利数量的截断问题和研发投入数据的缺失问题，可能使得实证结果存在系统性偏误。本文基于我国A股上市公司“管理层讨论与分析”（MD&A）文本数据，使用文本分析方法测度上市公司创新活动，克服了对无专利和研发数据缺失企业创新活动进行衡量的难题。结果显示，文本创新指标能够有效反映企业创新水平，与传统创新指标及企业未来经济绩效显著正相关，同时包含传统创新指标未能揭示的额外信息。基于文本分析方法，本文进一步构建了包括绿色、服务、供应链、管理及商业模式5个特定类型的创新指标，并尝试测度企业探索式创新水平，进一步拓展文本创新的应用范畴。本文为全面评估企业创新活动提供了新的研究视角和方法工具，对完善企业创新评价体系具有重要的理论价值和实践意义。

关键词：创新活动；文本分析；特定类型创新；探索式创新
DOI: 10.19343/j.cnki.11−1302/c.2025.02.006
中图分类号：F270　　**文献标识码：**A　　**文章编号：**1002−4565(2025)02−0070−14

Measuring Innovation Activities in China’s Listed Companies: A Text-Based Approach

Xie Jiasong　Fan Jiacheng　Lin Jianhao

Abstract: Most existing studies measure corporate innovation through patents or R&D investment. However, the truncation of patent data and the absence of R&D investment data may introduce systematic biases into empirical results. This study addresses these issues by using textual data from the Management Discussion and Analysis (MD&A) sections of the China’s A-share listed companies and constructs a novel text-based innovation measure, thereby overcoming the challenges of measuring innovation activities for firms lacking patent and R&D data. The results indicate that the text-based innovation measure can effectively reflect the level of corporate innovation, which is not only positively correlated with traditional innovation indicators and future economic performance, but also contains additional information that traditional innovation indicators fail to reveal. Based on this method, this study also constructs indices for five specific types of innovation: green, service, supply chain, management, and business model. In addition, this study attempts to measure the level of radical innovation to further expand the application of the text-based measure. This study provides a novel research perspective and methodological tool for

*基金项目：国家自然科学基金面上项目“基于文本大数据的宏观经济实时预测研究”（72073148）；国家自然科学基金青年项目“数字经济时代下创新扩散的阻碍因素与突破路径：专利文本测度、隐性壁垒识别与数据驱动机制研究”（72403030）；国家自然科学基金青年学生基础研究项目（博士研究生）“媒体叙事对公众预期与经济波动的影响研究——文本数据分析与信息选择建模”（723B2024）；教育部人文社会科学研究青年基金项目“公共数据要素如何赋能企业创新边界拓展：理论框架、测度方法与机制路径研究”（24YJC790199）。

中国知网　https://www.cnki.net

comprehensively measuring corporate innovation activities, offering both theoretical and practical insights for improving firm innovation evaluation systems.

Key words: Innovation Activity; Textual Analysis; Specific Types of Innovation; Radical Innovation

一、引言

创新对于经济持续增长的重要性已经得到广泛论证（Schumpeter，1934；Romer，1990），创新经济学逐渐成为经济学的重要分支领域。我国经济已经进入高质量发展阶段，创新作为引领经济发展第一动力的作用更加凸显。《中华人民共和国国民经济和社会发展第十四个五年规划和2035年远景目标纲要》强调，“坚持创新在我国现代化建设全局中的核心地位，把科技自立自强作为国家发展的战略支撑”。党的二十届三中全会进一步明确要求“激发全社会内生动力和创新活力”。对于企业而言，创新在企业短期利益和长期发展潜力的评估方面也同样发挥着核心作用，对其经营绩效、未来增长等均具有显著的正向影响。在这种实践导向变化和政策驱动下，创新成为国家和企业高质量发展的有效路径。

深入理解企业创新行为，一个重要前提是对包含复杂过程的创新活动进行准确全面的测度。长期以来，已有文献主要采用专利数量作为创新产出的代理变量，或者使用研发投入测度企业在创新活动中的贡献程度（吴超鹏和唐苟，2016）。然而，新近研究提出专利数据存在截断问题与显著异质性[①]，使用专利数据测度企业创新时可能会导致系统性错误（Lerner和Seru，2022）。更为重要的是，从熊彼特理论经典观点来看，创新是一种广泛的企业活动，不仅包括新的产品、新的生产方法，甚至还包括新市场开发（商业模式创新）或新的组织形式（管理创新）（Schumpeter，1934）。近年来，随着人工智能、云计算、大数据等新型技术的不断涌现，以数字化转型为代表的企业创新蓬勃发展。显然，现有企业层面创新指标并不能充分反映上述创新活动的性质和范围。大多现有研究依赖专利以及研发投入等数据，导致企业创新活动测度往往局限在有关新产品的创新中，且这种讨论只能囿于有专利产出的部门或披露研发投入的企业。根据本文统计，2008—2022年，我国A股非金融业上市公司29.1%的样本并未披露研究与试验发展（R&D）支出数据，超过50%的企业当年并未申请专利。此外，数据的偏误还存在行业结构的差异。譬如在服务业部门，企业的创新活动更多体现在商业模式的改变，而这一部分创新并不能被专利及研发投入很好地识别。此外，出于对商业机密的保护，企业还可能未对部分创新产出申请专利以避免商业化（Saidi和Žaldokas，2021）。综上所述，鉴于现有实践中存在的问题，需要尝试使用新的方法测度创新。

为弥补传统创新活动代理变量的缺陷，本文基于2008—2022年我国A股上市公司“管理层讨论与分析”（MD&A）文本信息，通过设定刻画企业创新活动的术语词典，利用词袋计数法构造一种基于文本的企业创新水平度量。创新作为企业生产经营的重要活动和发展战略的重要内容，上市公司有强烈的披露意愿以获得资本市场青睐，这类信息往往体现在具有指导性质且为外部投资者提供重要参考的年报MD&A部分。企业MD&A文本在一些创新术语的使用和表达方面的确涵盖了与企业创新活动相关的内容[②]，因此从涉及“企业创新”相关表述的角度来刻画其创新程度，具有一定的可

①一方面，专利从申请到授权存在时间差异，因此在数据库涵盖时间的末期都会存在截断问题；另一方面，不同专利价值差异较大，授权人也存在异质性。

②本文整理了部分上市公司MD&A文本。因篇幅所限，上市公司年报MD&A文本与创新相关内容以附表1展示，见《统计研究》网站所列附件。下同。

中国知网　https://www.cnki.net

行性和科学性。研究表明，文本创新指标能够有效度量企业创新水平。一方面，该指标与不同维度的传统创新指标存在显著正相关关系。另一方面，在控制传统创新指标之后，文本创新指标依旧与企业当期和未来的经济绩效显著正相关。这意味着文本创新指标包含了传统创新指标所未能体现的额外信息。进一步地，本文探索利用文本数据度量企业创新活动的独特优势。相比而言，基于文本的创新指标能更全面地测度特定类型的创新水平，包括度量绿色、服务、供应链、管理及商业模式等多维度的企业创新活动。此外，本文还尝试利用文本数据构造企业的探索式创新指标并进行实际测度，表明其能较好地度量未来企业技术边界的拓展。

本文可能的边际贡献主要体现在以下两个方面。一是本文的工作有助于拓展现有创新经济学的实证研究思路。基于文本的创新度量能够识别并了解企业的非专利创新活动，以及研发投入缺失企业的实际创新情况。这有效避免了现有文献只从专利产出或研发投入测度创新所导致的样本偏误问题。二是基于文本的度量方法对创新活动的测算范围更广，包括但不限于服务创新、管理模式创新、探索式创新等，测度结果有助于准确掌握企业创新状况，对于推动创新政策的精准制定、优化创新资源配置以及提升企业创新效率具有重要意义。

二、文献综述

随着互联网发展和大数据分析的普及，文本数据成为经济学、金融学领域研究中发展相对较快的一种数据形式，对传统研究通常使用的结构化数据具有非常好的补充作用（Gentzkow等，2019）。特别地，文本数据在公司金融领域有广泛应用。一方面，已有研究利用企业相关的文本提取情绪、语调、可读性等指标，研究其与企业活动的联系。例如，Li（2010）以及Loughran和McDonald（2011）分别利用美国上市公司报告的MD&A和全文内容，通过度量管理层语调和年报语调，发现上市公司文本的语调与收益率、未来盈利能力等企业业绩指标密切相关。Loughran和McDonald（2014）则使用10-K年报的文件大小衡量可读性，发现可读性差的公司在年报发布后的收益率会降低，而波动率、盈利预测误差和分歧将会增大。另一方面，现有研究也尝试从文本分析视角更新对已有衡量企业生产经营活动指标的测度方法。具有代表性的是，Hoberg和Maksimovic（2015）基于1997—2009年上市公司10-K年报中的流动性与资本资源部分，通过设定打分规则获得基于文本的财务约束测度。Hoberg和Phillips（2016）则根据10-K年报中与企业产品描述的相关内容，结合余弦相似度和聚类算法提出一种基于文本网络的行业分类法。此外，文本分析方法也为传统数据难以量化的指标提供新的测度思路。譬如，Hassan等（2019）利用在美上市公司的季度收益电话会议记录，通过计算语言学技术测度了公司层面的政治风险暴露，发现该指数与公司行动（如招聘、投资）和股票市场波动密切相关。

近年来，国内学者同样从以上两种研究视角将文本数据应用于公司金融研究。谢德仁和林乐（2015），以及林乐和谢德仁（2017）基于上市公司业绩说明会文本，根据词典法测度管理层语调，发现管理层净正面语调与未来公司业绩正相关，并提高了分析师更新荐股报告的可能性、更新人数比例和荐股评级水平。姜付秀等（2017）借鉴Hoberg和Maksimovic（2015）的文本分析方法，基于我国A股上市公司年报的MD&A构建融资约束指标，发现公司大股东数量较多的企业具有较低的融资约束水平。张成思等（2021）基于我国上市公司年报的MD&A部分，通过设定特定计算规则首次构建了公司的宏观经济感知指数，发现在宽松货币政策下，对宏观经济感知更为乐观的企业将更积

中国知网　https://www.cnki.net

极响应政策刺激，以增加投融资行为。此外，部分学者尝试根据上市公司年报，通过构建专业词典测度企业的数字化转型程度或人工技术（吴非等，2021；李成明等，2023；姚加权等，2024），拓宽了文本分析在经管研究中的应用。

关于使用文本数据测度企业创新活动的研究中，Bellstam等（2021）利用主题模型，从S&P500公司的分析师报告中测度创新指数，发现基于文本构建的创新指标与传统创新指标密切相关，而对于专利较少但同样进行创新的公司则捕获了与新技术采用或商业实践创新的相关内容。郭冬梅等（2024）也基于该方法进行了实证分析。这些前沿尝试一方面仅考察了企业创新的总体特征，没有关注到与特定技术或特定产业相关的创新活动。另一方面，也一定程度上忽视了企业的异质性创新行为。在企业业务多元化的背景下，如何考虑多维度、多层次创新活动仍是亟待解决的重要问题。最后，尤为重要的是，基于文本测度我国企业创新活动，需要考虑我国的创新政策实践以及中文的特殊表达，进而构建适用于中国情境的创新词典。

三、基于文本数据的创新度量

（一）基于文本的企业创新水平度量

上市公司通常在年报中的“管理层讨论与分析”（MD&A）部分对企业的经营状况、未来发展规划等内容进行详细描述和披露，为外部投资者提供重要信息。因此，文献常以该部分文本为原始语料进行公司行为分析（Durnev和Mangen，2020；吴非等，2021；姚加权等，2024），本文也沿用了这一做法。具体而言，本文首先尝试建立一个相对完备、定义准确且适用于描述企业创新活动相关词语的词典，继而基于该词典构建能够较为全面反映上市企业创新活动的文本指标。指标的具体构造流程如图1所示。

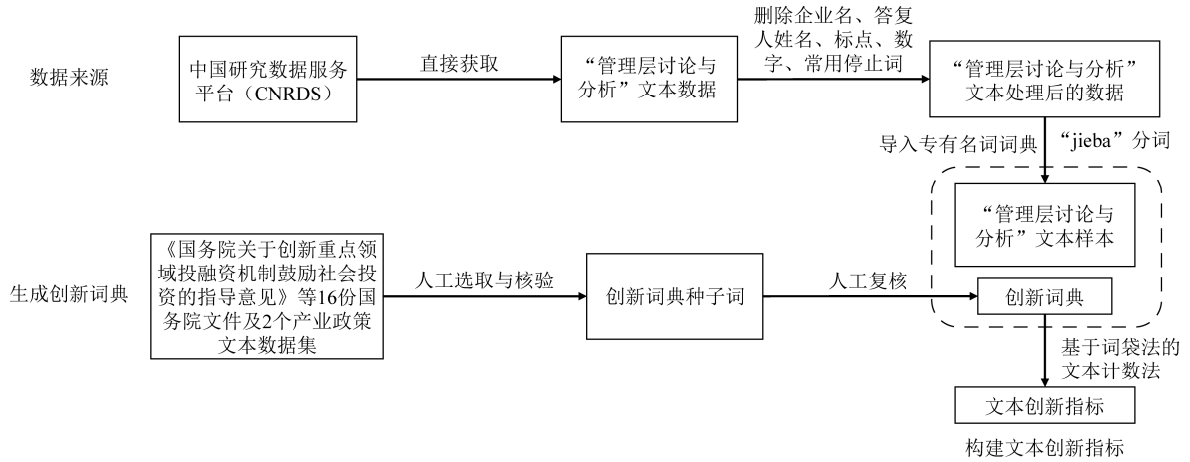


图1　文本创新指标的构造过程示意图

第一步，构建企业创新术语词典。现有国内外研究均缺乏衡量企业创新活动的专用术语词典，为了保证词典的准确性和权威性，本文分别借鉴学术领域和实践领域的相关文献和文件，归纳整理了一系列隶属于企业创新主题的专用术语。具体而言，在学术文献方面，本文参考Bellstam等（2021）公布的创新主题相关词语列表，以及与企业创新活动密切相关的数字化转型相关研究（吴非等，2021），归纳整理出表示创新的特定关键词。在实践领域方面，本文以《国家创新驱动发展战略纲要》

中国知网　https://www.cnki.net

等16份国务院文件[①]和近年《政府工作报告》为蓝本，进一步筛选和扩充与创新相关的特征词库。为保证最大限度体现企业整体的创新水平而非聚焦于某项特定技术或某个特定领域的创新活动，本文对某些特定词语进行剔除。例如，可视电话、可穿戴产品、数码设备等词语可能与特定行业产品方面的创新相关，纳入词典考量会有失偏颇。经人工复查核对，最终筛选得到36个词频高于100次的企业创新相关词汇，这些词汇构成了本文所定义的基准创新词典 $\mathcal{J}$ [②]。

第二步，对MD&A文本进行分词和预处理。与已有研究一致，本文使用Python软件包的jieba中文分词库，对上市公司年报MD&A部分进行分词，并保留所有出现在创新词典中的创新术语不被切分。由于经济金融领域的特定术语往往容易被错误识别或错误切分[③]，为此添加搜狗词库中三个下载量较大的财经词库[④]至jieba专用词典模块，以尽可能提高对专有名词的识别效率（姜富伟等，2021）。此外，本文还进行以下预处理操作以提高文本分析的质量。一是剔除数字、英文表达、中英文标点和常见停用词（如比如、居然等），删除年报文本常见但无具体含义的词语（如公司、董事会等），仅保留词语长度大于或等于2的词语；二是对MD&A文本中有明显错误（如拼写错误或分词有误）的词语进行人工核对和替换，如将“项专利”替换为“专利”，将“项发明”替换为“发明”等；三是对分词后的文本进行多次人工校验和核对，以尽可能避免分词错误带来的测度误差。

第三步，构建基于文本的企业创新水平度量。基于预处理后各个企业的MD&A文本，统计创新词典中36个创新术语的出现总频率，并以总文本语段长度进行标准化，得到基于MD&A文本的企业创新水平度量（$Text_inv_{it}$）：

$$Text_inv_{it}=\frac{\sum_{c}^{C_{it}} I\left(c\in\mathcal{J}\right)}{C_{it}} \tag{1}$$

其中，若词语 c 为创新术语，则 $I\left(c\in\mathcal{J}\right)$ 取1；反之取0。C_{it} 为企业 i 在第 t 年MD&A文本经预处理后的有效词数。直观来讲，$Text_inv_{it}$ 衡量了与企业创新相关术语在其MD&A文本中出现的占比，若该指标数值越大，表示在MD&A中披露或讨论创新相关的内容越多，企业创新活动越活跃。

（二）文本创新指标和传统创新指标的关系

传统创新指标包括企业的创新产出、投入、质量和效率4个维度。具体而言，创新产出指标采用企业当年申请的所有专利数量的自然对数度量[⑤]，创新投入采用企业R&D支出的自然对数度量，创新质量采用企业当年申请专利被引用数量的自然对数度量，相关数据来源于中国研究数据服务平台（CNRDS）。最后，企业创新效率指标构造具体如式（2）所示：

$$IE_{it}=\log\left(1+\frac{Patent_{it}}{RD_{it}+0.8RD_{it-1}+0.6RD_{it-2}}\right) \tag{2}$$

①16份文件包括《国家创新驱动发展战略纲要》《国务院关于印发“十三五”国家科技创新规划的通知》《国务院关于促进云计算创新发展培育信息产业新业态的意见》《国务院关于印发“十二五”国家自主创新能力建设规划的通知》《国务院关于创新重点领域投融资机制鼓励社会投资的指导意见》《国务院关于促进加工贸易创新发展的若干意见》《国务院关于大力推进大众创业万众创新若干政策措施的意见》《国务院关于加快构建大众创业万众创新支撑平台的指导意见》《国务院关于印发北京加强全国科技创新中心建设总体方案的通知》《国务院关于印发上海系统推进全面创新改革试验加快建设具有全球影响力科技创新中心方案的通知》《国务院关于强化实施创新驱动发展战略进一步推进大众创业万众创新深入发展的意见》《国务院关于推动创新创业高质量发展打造“双创”升级版的意见》《国务院关于支持自由贸易试验区深化改革创新若干措施的通知》《国务院关于推进国家级经济技术开发区创新提升打造改革开放新高地的意见》《国务院印发关于推进自由贸易试验区贸易投资便利化改革创新若干措施的通知》《国务院关于印发中国落实2030年可持续发展议程创新示范区建设方案的通知》。

②因篇幅所限，具体创新术语词表以附表2展示，词云图以附图1展示。

③例如，在不添加专业术语词典的情况下，“资产证券化”这一金融术语将被误切分为“资产”和“证券化”两个独立词语。

④三大财经词库分别为财经金融词汇大全、财会词汇大全和股票金融词汇。

⑤由于从专利申请到最终授权通常需要较长时间，会导致专利授权数据存在较大滞后性，会存在较为严重的截断问题（Lerner和Seru，2022），考虑到专利技术在申请期就代表了企业发生创新活动，本文采用专利申请数据进行分析。

中国知网　https://www.cnki.net

其中，$Patent_{it}$ 为 i 企业第 t 年申请专利数量，RD_{it} 为企业研发投入，考虑创新活动周期较长，故以三年为窗口期对 RD_{it} 进行折旧处理，每年折旧率为20%。由于企业样本量过大，本文使用分仓方法绘制散点图和拟合线①。具体而言，将文本创新和传统创新指标平均由低到高分为100等份，取指标组内均值进行图形绘制。直观来看，企业的文本创新指标和创新产出、投入、质量和效率4个传统指标均呈现正相关关系，意味着文本创新指标包含了创新活动4个维度的相关重要信息。

（三）无专利与无R&D支出企业的文本创新指标

使用文本信息度量企业创新的一个重要优势是，能够很好地捕捉且识别出那些未申请专利或未披露研发支出企业的创新活动。虽然文献普遍认为专利申请与创新绩效高度相关，但可以预期的是，由于行业或企业自身差异，存在着部分企业没有专利，但仍具有活跃创新活动的情形。为了更好地比较分析，根据企业当年有无申请专利进行分组。由文本创新指标的箱线分布图②可以发现，一般而言有专利申请的上市公司具有更高文本创新水平，同时那些当年未申请专利的企业仍具有一定程度的创新，而这些企业的创新活动在使用专利测度的研究中往往被忽视。

与美国不同的是，我国上市公司中约30%的企业样本没有披露R&D支出数据，该类数据缺失并不意味着企业没有进行研发创新活动，这可能只是企业在信息披露方面的某种策略性行为，由此将导致基于R&D支出数据测度企业创新投入的研究结论存在一定程度的偏误。根据是否披露R&D支出数据将企业进行分组，结果表明，有R&D支出数据的企业展现出更高的文本创新度，无R&D支出数据的企业也具有一定的创新活动。

为详细比较不同组别企业的系统性差异，本文基于企业是否申请专利以及企业是否有R&D支出数据绘制的文本创新指标的核密度图。可以发现，具有申请专利和R&D支出企业的文本创新分布都更为厚尾且偏右，体现出了更高的创新水平。此外，即使那些无申请专利或R&D投入缺失的企业组内部，创新水平同样存在较大差异。因此这些企业被归0亦或直接删去等处理方法会使得实证结果产生系统性偏误③。

四、文本创新指标与企业经济绩效

（一）模型设定和变量选取

现有研究普遍认为，创新会对企业未来的增长和价值产生持久的正向促进作用（吴超鹏和唐菂，2016；Bellstam等，2021）。一方面，企业的创新活动能够为企业获得竞争优势，增加经济回报和市场份额；另一方面，投资者也倾向于创新型企业，理性地估计该企业未来现金流增加，从而推动其市场价值的提高。因此，创新活动越活跃的企业，其未来价值、财务绩效和增长率会高于低创新水平企业。前文已论证了文本创新指标包含了传统创新指标所未能体现的企业创新信息，为考察企业创新信息对当期及未来绩效的影响效应，设定实证模型式（3）。

$$y_{it+\tau}=\alpha_0+\alpha_1 Text_inv_{it}+\boldsymbol{X}'_{it}\boldsymbol{\alpha}_2+T_t+D_s+\varepsilon_{it+\tau} \quad (3)$$

其中，i 为企业，t 为年份，s 为企业所属行业，$\tau=0,1,2$，代表延迟期数，故 $y_{it+\tau}$ 度量了企业当期及未来 τ 年的指标。本文主要从财务绩效、企业价值及成长性三个维度考察企业绩效。遵循现有文献研究思路（吴超鹏和唐菂，2016；Bellstam等，2021），企业的财务绩效（*Profit*）采用企业当期营业利润占期末总资产的比重度量；企业价值（*TobinQ*）使用托宾Q值度量，高托宾Q值意味着高

①因篇幅所限，文本创新指标与传统创新指标的拟合关系以附图2展示。

②因篇幅所限，有专利申请与无专利申请、有披露和无披露R&D支出数据企业的文本创新分布箱线图以附图3展示。

③因篇幅所限，不同分组下的企业文本创新指标的核密度图以附图4展示，文本创新指标的组间差异结果以附表3展示。

中国知网　https://www.cnki.net

产业投资回报率和高企业价值，其具体计算公式为：托宾Q值=（股权市值+净债务市值）/企业总资产；成长性（*Growth*）使用企业营业收入当期增长率度量。$Text_inv_{it}$ 为使用文本方法测度所得的创新指标。$\boldsymbol{X}_{it}$ 为一系列控制变量，具体包括企业的规模、负债、股权集中度、金融资产规模、董事会独立性、产权性质以及家族企业特征等因素[①]，所有连续变量均进行了上下1%的缩尾处理。T_t 和 D_s 分别为年份及行业虚拟变量，$\varepsilon_{it+\tau}$ 为随机扰动项。相关数据来源于CSMAR数据库[②]。最终，得到4724个企业在2008—2022年共计41412个观测值进行分析。

（二）基准回归结果

表1为文本创新指标对企业当期及未来绩效表现影响的实证结果。整体而言，基于文本度量的创新和企业当期及未来的经济绩效均呈现显著正相关关系，并且具有符合预期方向的预测能力，表明本文基于文本刻画的创新指标可以较好地捕捉企业的创新活跃程度，包含影响企业未来绩效的额外信息。

表1　　**文本创新与企业经济绩效**

	$Profit_{it+\tau}$		$TobinQ_{it+\tau}$		$Growth_{it+\tau}$	
	（1）	（2）	（3）	（4）	（5）	（6）
Panel A：$\tau=0$						
文本创新	0.7934***	0.2868***	3.2001***	3.4056***	1.0800***	0.8726***
	（0.0635）	（0.0586）	（0.8129）	（0.7383）	（0.2219）	（0.2210）
观测量	41412	40301	40719	39612	36587	35792
R^2	0.0197	0.1289	0.1293	0.3001	0.0505	0.0678
Panel B：$\tau=1$						
文本创新	0.6954***	0.3068***	6.1508***	4.7602***	0.5666***	0.4280**
	（0.0566）	（0.0554）	（0.8956）	（0.8097）	（0.2177）	（0.2157）
观测量	36632	36381	36021	35772	36604	36353
R^2	0.0243	0.1037	0.1333	0.2892	0.0498	0.0653
Panel C：$\tau=2$						
文本创新	0.6432***	0.3279***	6.5469***	4.9646***	0.3750*	0.1798
	（0.0624）	（0.0614）	（0.9465）	（0.8640）	（0.2274）	（0.2263）
观测量	32424	32230	31851	31658	32325	32131
R^2	0.0167	0.0557	0.1336	0.2823	0.0532	0.0644

注：括号内为稳健标准误；*、**及***分别代表10%、5%及1%的显著性水平；所有列模型均控制了年份及行业固定效应；列（1）、（3）、（5）未控制企业层面的控制变量，列（2）、（4）、（6）控制了企业层面的控制变量。

（三）文本创新和专利数量对企业经济绩效影响的比较

为了比较文本创新指标和专利数量指标在预测企业未来绩效方面的表现，本文在式（3）的基础上纳入企业专利申请数量作为解释变量进行比较，结果如表2所示。Panel A结果显示，在控制企业层面相关特征后，专利数量对企业下一期的经济绩效具有显著的正向影响。加入文本创新指标后，文本创新指标仍然对企业下一期的绩效具有显著为正的影响。此外，在加入文本创新指标后，专利对

①企业资产使用企业当年期末总资产的自然对数度量、负债使用企业当年总负债占总资产的比例度量、股权集中度选用企业当年前三大股东持股比例度量、金融资产规模为企业金融资产持有占总资产比例度量、董事会独立性选用企业当年独立董事人数度量。企业所有制为虚拟变量，企业若属于国有企业赋值为1，否则取0。家族企业为虚拟变量，企业若属于家族企业赋值为1，否则取0。

②因篇幅所限，各变量定义以及描述性统计以附表4展示。

中国知网　https://www.cnki.net

企业托宾Q值的积极影响消失了，对企业增长的统计显著性也有所下降，表明文本创新对企业经济绩效的影响一定程度可以替代专利包含的信息。最后，Panel B列（1）和列（2）的结果表明，文本创新指标的加入使模型拟合优度提高32%，而在托宾Q值方程和营业收入增长率方程中，甚至有更大的拟合优度提升。因此，相比于专利变量，基于文本构造的创新指标对企业未来的财务绩效具有额外且重要的影响。

表2　　文本创新与专利申请数量对企业经济绩效的预测效果比较

	$Profit_{it+1}$		$TobinQ_{it+1}$		$Growth_{it+1}$	
	（1）	（2）	（3）	（4）	（5）	（6）
Panel A：控制控制变量和固定效应						
文本创新		0.2181***		4.6656***		0.3698*
		（0.0552）		（0.8128）		（0.2169）
log（1+申请专利数量）	0.0035***	0.0033***	0.0079*	0.0032	0.0023**	0.0021*
	（0.0003）	（0.0003）	（0.0043）	（0.0043）	（0.0012）	（0.0012）
观测量	36597	36374	35988	35765	36571	36348
R^2	0.1066	0.1067	0.2883	0.2892	0.0650	0.0653
Panel B：不控制控制变量和固定效应						
文本创新		0.4186***		11.5613***		1.7757***
		（0.0503）		（0.8250）		（0.1989）
log（1+申请专利数量）	0.0040***	0.0034***	–0.0245***	–0.0420***	0.0055***	0.0029***
	（0.0002）	（0.0002）	（0.0042）	（0.0043）	（0.0010）	（0.0010）
观测量	36868	36623	36256	36012	36842	36597
R^2	0.0068	0.0090	0.0009	0.0069	0.0008	0.0031

（四）稳健性检验

1.创新词典的拓展。

为了提高创新词典的全面性，本文对基准的创新词典进行词语扩充。使用Word2vec技术Skip-gram模型（Mikolov等，2013），将MD&A中的词语作为语料进行训练，筛选与已有创新术语余弦相似度较高且符合创新语义的词语，最终在基准创新词典的基础上补充123个新的创新术语[①]。根据式（1）重新构建基于拓展词典的文本创新指标，继而检验其对企业未来经济绩效预测能力的稳健性。表3结果显示，拓展创新词典后构建的文本创新指标仍与企业未来经济绩效显著正相关。

表3　　基于Word2vec拓展词典的文本创新与企业经济绩效稳健性检验

	$Profit_{it+1}$		$TobinQ_{it+1}$		$Growth_{it+1}$	
	（1）	（2）	（3）	（4）	（5）	（6）
文本创新（拓展度量）	0.5583***	0.2387***	2.9955***	2.4581***	0.3711**	0.2883*
	（0.0449）	（0.0441）	（0.7260）	（0.6520）	（0.1739）	（0.1716）
观测量	36632	36381	36021	35772	36604	36353
R^2	0.0242	0.1036	0.1323	0.2886	0.0497	0.0652

注：所有列模型均控制了年份及行业固定效应。列（1）、（3）、（5）未控制企业控制变量，列（2）、（4）、（6）控制了企业控制变量，下同。

①词与词之间余弦相似度的计算方式如下。一是利用Mikolov等（2013）提出的Word2vec词嵌入（Word Embedding）技术，使用MD&A文本作为原始语料库，利用Skip-gram训练方法将词语映射成低维连续向量空间中的向量，即“词向量”。参考已有文献常用标准，本文选取词向量维度为 $n=200$ 。二是基于该200维的词向量，计算两个词语之间的余弦相似度（王靖一和黄益平，2018）。根据本文模型的训练结果，“研发”与“创新”两个词的相似度达到0.56，“新技术”与“创新”的相似度为0.60。当然，“创新”与“创新”的相似度为1。因篇幅所限，有关Word2vec算法的具体使用细节见附录1，具体拓展词典额外扩充的创新术语以附表5展示。

中国知网　https://www.cnki.net

2.创新术语的重要程度。

借鉴Hassan等（2019）的做法，本文将不同创新词语的相对重要程度纳入考量，即在式（1）的基础上对分子进行权重设定：

$$Text_inv_wt_{it}=\frac{\sum_{c}^{C_{it}} I(c\in\mathcal{J})\times w(c\in\mathcal{J})}{C_{it}} \tag{4}$$

其中，权重 w 衡量了创新术语 c 的相对重要性。设定以下6种权重，第一种，体现创新术语在创新程度上的语义差异。由于中文表述中，不同创新术语所表达的创新程度存在差异，例如首创、独创等词语表达的创新性程度应高于新途径、新工艺等词语。为了体现不同创新术语的创新语义差异，采用人工评分以及相关自然语言处理工具评分相结合的方式，对基准创新词典中所有的创新术语进行评分[①]，进而以评分作为权重由式（4）重新计算文本创新指标。表4报告了调整后文本创新对于企业经济绩效的影响，基于基准词典和拓展词典的度量指标均显著提高了企业经济绩效，说明在考虑创新术语的重要程度后，文本创新指标测度是稳健的。

表4　　基于创新语义程度调整的文本创新与企业经济绩效稳健性检验

	$Profit_{it+1}$		$TobinQ_{it+1}$		$Growth_{it+1}$	
	（1）	（2）	（3）	（4）	（5）	（6）
Panel A：基准词典度量						
文本创新（语义调整）	0.3782***	0.1743***	2.7923***	2.0493***	0.3830***	0.2942***
	（0.0293）	（0.0287）	（0.4616）	（0.4158）	（0.1130）	（0.1121）
观测量	36632	36381	36021	35772	36604	36353
R^2	0.0248	0.1039	0.1329	0.2889	0.0499	0.0654
Panel B：拓展词典度量						
文本创新（语义调整）	0.2951***	0.1421***	1.3900***	1.2727***	0.2065***	0.1657**
	（0.0204）	（0.0201）	（0.3366）	（0.3007）	（0.0793）	（0.0780）
观测量	36632	36381	36021	35772	36604	36353
R^2	0.0258	0.1042	0.1323	0.2887	0.0498	0.0653

第二种，参考王靖一和黄益平（2018）、姜富伟等（2021）的做法，本文设定余弦相似度权重以测度创新词典中某一术语与“创新”一词的相关程度，即与“创新”语义相似度越高的词语，代表与企业创新水平越相关。第三种，从词语出现次数的角度衡量创新术语的相对重要性（Hassan等，2019）。第四种，计算创新术语在总语料库的词频–逆文档频率（TF-IDF），从总文档出现次数的角度衡量词语重要性的同时包含低频但有效的文本信息（Ellingsen等，2022）。最后，分别使用相似度和频率、相似度和TF-IDF结合的加权方式，以考察权重组合的稳健性[②]。

3.否定性表述的影响。

由于上市公司年报在披露创新相关内容时可能会出现否定性表述，本文通过识别创新术语前是否有否定性词汇来重新调整企业文本创新指标：

$$Text_inv_neg_{it}=\frac{\sum_{c}^{C_{it}} I(c\in\mathcal{J})\times Neg_{l}}{C_{it}} \tag{5}$$

①借鉴相关文献，本文采用主观赋值对创新术语的创新语义程度进行人工评分。因篇幅所限，具体评分规则及评分情况以附录2及附表6展示。

②因篇幅所限，权重计算规则以及含义见附表7，选用不同权重构造文本创新度量对企业绩效影响见附表8~10。

中国知网　https://www.cnki.net

其中，Neg_l 为考虑创新术语 c 前 l 个词范围内出现否定性表述的调整因子。本文考虑两种设定形式，其一，语义逆转，即设定 $Neg_l=(-1)^n$，其中 n 为否定性词语个数。当创新术语前否定性词语个数为奇数时，创新术语的语义表示否定倾向，该创新术语对应的语义出现逆转，文本创新指标的分子减1；其他情况下，创新术语对应语义不变，故不作调整。其二，术语删除，即设定 $Neg_l=0$，若创新术语前出现否定性表述则不统计该术语。根据中国知网否定性词语表定义否定性词语集，经人工补充、调整后最终确定38个否定性词语集合；设定创新术语与否定性词语的距离标准 $l=3,5,10$，计算经过否定性表述调整后的文本创新指标。

表5展示了考虑否定性表述调整后文本创新对未来一期企业经济绩效的影响效果。Panel A、Panel B和Panel C分别为设定创新术语与否定性词语的距离为3、5和10情形下的估计结果。列（1）~（3）为基于否定表述的语义逆转设定，列（4）~（6）为基于否定表述的术语删除设定。结果发现，回归系数的方向与显著性仍与基准结果高度一致。

表5　　基于否定性表述调整的文本创新与企业经济绩效稳健性检验

	语义逆转			术语删除		
	$Profit_{it+1}$	$TobinQ_{it+1}$	$Growth_{it+1}$	$Profit_{it+1}$	$TobinQ_{it+1}$	$Growth_{it+1}$
	（1）	（2）	（3）	（4）	（5）	（6）
Panel A：$l=3$						
文本创新（否定性调整）	0.3068***	4.7619***	0.4296**	0.3068***	4.7612***	0.4288**
	（0.0554）	（0.8098）	（0.2157）	（0.0554）	（0.8098）	（0.2157）
观测量	36381	35772	36353	36381	35772	36353
R^2	0.1037	0.2892	0.0653	0.1037	0.2892	0.0653
Panel B：$l=5$						
文本创新（否定性调整）	0.3073***	4.7583***	0.4282**	0.3070***	4.7595***	0.4281**
	（0.0554）	（0.8096）	（0.2157）	（0.0554）	（0.8097）	（0.2157）
观测量	36381	35772	36353	36381	35772	36353
R^2	0.1037	0.2892	0.0653	0.1037	0.2892	0.0653
Panel C：$l=10$						
文本创新（否定性调整）	0.3079***	4.7611***	0.4320**	0.3074***	4.7613***	0.4300**
	（0.0554）	（0.8102）	（0.2158）	（0.0554）	（0.8100）	（0.2157）
观测量	36381	35772	36353	36381	35772	36353
R^2	0.1037	0.2892	0.0653	0.1037	0.2892	0.0653

注：所有列模型均控制了企业控制变量、年份及行业固定效应。

五、文本创新指标的拓展应用

（一）度量特定类型创新活动

创新是一种非常广泛的企业活动，不仅包括新的产品、新的生产方法，还包括市场、供应、组织等创新（Schumpeter，1934），而专利数量、R&D支出等传统企业创新指标无法反映商业模式、供应链、组织管理等维度的创新。由于这些维度的创新是企业业绩亮点与发展方向，故上市公司有强烈意愿在年报中披露相关信息，以获得市场认可。因此，文本分析方法可以通过识别某一专项术语以及在该语境下的讨论是否与创新相关来构造特定类型创新活动，从而捕捉传统指标所不能描述的创新，符合当下对创新活动关注愈加细化的需要，并描绘相应的特征事实。

本文具体讨论了5个特定类型创新，包括绿色、服务、供应链、管理和商业模式。为每个特定类

中国知网　https://www.cnki.net

型的创新构造一个“限定词词典”，并利用Word2vec进行词扩充，以丰富特定类型创新的相关词语。针对特定类型创新活动的合理细分，可以通过关键词匹配与创新词典结合的方式，测度基于特定技术或某些领域、细颗粒度的创新水平。具体步骤如下。

第一，根据所考察的特定技术或领域构造不同创新词典 $\mathcal{M}_j$。例如，若考察与绿色环保方面的企业创新，则该词典中可能包括“低碳”“节能”“环保”等词语。

第二，在MD&A文本中，统计特定类型创新词典与创新词典中词语共同出现的次数。具体而言，对于第 t 年的企业 i，特定类型创新 j 的创新水平测度为

$$Text_inv_{it}^{j}=\frac{\sum_{c\in\mathcal{J}}\sum_{u}^{C_{it}} I\left(u\in\mathcal{M}_j\right)\times I\left(\left|u-c\right|<l\right)}{C_{it}} \tag{6}$$

其中，词 $c\in\mathcal{J}$ 为创新词典的创新术语，$u\in\mathcal{M}_j$ 为特定类型创新 j 的专用术语；$I\left(u\in\mathcal{M}_j\right)\times I\left(\left|u-c\right|<l\right)$ 取1，当且仅当出现专用术语 u，且该术语与创新术语 c 距离足够接近，即 $\left|u-c\right|<l$，即说明该语段在讨论与特定类型创新 j 相关的创新内容。参考Hassan等（2019）的设定，$l=10$。

关于特定类型创新的讨论，由于上市公司有绿色专利数据详细指标而缺乏其他维度的创新信息，本文以此为例考察企业绿色文本创新和绿色专利之间的相关性，然后给出其他特定类型创新的文本创新指标在行业层面的描述性统计。

1.绿色创新的文本测度与绿色专利。

本文所使用的上市企业绿色专利申请数量数据来源于CNRDS绿色专利研究数据库。该数据库是结合中国专利数据以及世界知识产权局公布的绿色专利分类号标准而匹配开发的专业数据库。基于此，使用上市公司当年申请的所有绿色专利数量（对数加1形式）作为企业绿色创新产出的度量。表6展示了不同权重构造的企业绿色文本创新指标对企业下一年绿色专利申请数量（$Patent_green_{it+1}$）的影响。结果显示，基于文本构造的绿色创新估计系数均在1%的统计水平显著为正，即其与企业未来绿色专利申请数量具有高度正相关关系，因此该指标能够有效地捕捉企业未来的绿色创新产出。

表6　　绿色文本创新与绿色专利

	$Patent_green_{it+1}$			
	（1）	（2）	（3）	（4）
绿色创新（基准词典度量）	6.0071***（0.5233）	4.6743***（0.5093）		
绿色创新（拓展词典度量）			1.0963***（0.1360）	1.1084***（0.1335）
观测量	36632	36381	36632	36381
R^2	0.0346	0.0758	0.0298	0.0739

注：所有列模型均控制了年份及行业固定效应。列（1）、（3）未控制企业控制变量，列（2）、（4）控制了企业控制变量。

2.特定类型创新的行业异质性。

本文依次计算了绿色、管理、服务、商业模式、供应链5类特定类型创新在行业层面的异质性，可以总结为以下典型事实①。第一，对比5个特定类型创新，商业模式创新广泛存在于上市公司之中，无论是制造业、服务业抑或第一产业，商业模式创新水平均是最高的。而商业模式的创新无法体现在专利数据中，这意味着传统创新度量可能低估了企业整体的创新活动。相比之下，绿色创新活动在所有行业中均较低，企业在绿色创新方面仍有较大的提升空间。第二，分类来看，绿色创新水平最高的三个行业分别为水利、环境和公共设施管理业，电力、热力、燃气及水生产和供应业以及科

①因篇幅所限，具体的不同行业特定类型文本创新特征以附图5展示。

中国知网 https://www.cnki.net

学研究和技术服务业；管理创新水平最高的三个行业分别为住宿和餐饮业、综合行业及制造业[①]；服务创新水平最高的三个行业为信息传输、软件和信息技术服务业，文化体育和娱乐业以及科学研究和技术服务业；商业模式创新最高的三个行业分别为信息传输、软件和信息技术服务业，科学研究和技术服务业及制造业；供应链创新最高的三个行业为制造业，综合行业，科学研究和技术服务业。这一定程度上描绘了当下微观企业的创新活动特征事实。第三，整体而言，制造业，信息传输、软件和信息技术服务业，科学研究和技术服务业三个行业拥有较高的创新水平；而居民服务、修理和其他服务业在各个维度的创新都较低。

（二）度量企业探索式创新

我国当前的创新面临着高数量、低效率与低质量“一高两低”困境（沈坤荣等，2023；叶初升和孙薇，2023）。究其原因，可能是渐进的小幅度创新活动过多而扩展新市场的探索式创新较少。文本这类非结构化数据具有细颗粒度、信息含量丰富的独特优势，有助于更加合理地评价与识别企业探索式创新活动。本文将探索式创新定义为企业对新技术领域的开发和突破（Byun等，2021），能够突破边际收益递减规律，成为企业增长的核心引擎。沿袭基准文本创新度量的构造思路，尝试在创新词典中搜集与“探索式创新”相关的术语，定义探索式创新词典 $\mathcal{H}$，构造如下探索式创新的文本度量：

$$Text_inv_exp_{it}=\frac{\sum_{c}^{C_{it}} I\left(c\in\mathcal{H}\right)}{C_{it}} \tag{7}$$

其中，创新术语 c 属于探索式创新词典则 $I\left(c\in\mathcal{H}\right)$ 取1，反之取0；其他符号含义同上。本文通过以下方式确定探索式创新词典，第一，基于对探索式创新的定义和语义理解，首先剔除明显与“探索”语义不符的创新术语，例如“更新”“推陈出新”“迭代”“升级”等。这是因为这些词语主要表达了在原有业务、产品、技术等纵向层面的创新和升级，未能体现探索式创新对其他全新业务领域的横向拓展。第二，基于本文训练的Word2vec模型计算创新词典中创新术语与“探索”“开辟”“拓展”等可能与探索式创新相关描述词语的相似度，仅保留相似度较高的术语，这一步过滤掉“研发”“发明”“专利”等词语。第三，结合年报MD&A文本的相关表述，借助人工和相关模型判断剩余创新术语纳入探索式创新词典是否合适[②]。

进一步地，本文验证基于文本度量的探索式创新是否有助于预测未来企业对新技术领域的开发和突破，即拓展其创新边界。遵循Byun等（2021）的变量构造思路，基于企业过去申请的专利技术类别来识别企业在新领域的创新探索。第一，以专利的国际专利分类号（International Patent Classification，IPC）作为专利技术领域的划分依据；第二，以企业专利所属IPC六位码为依据进行分类；第三，时间窗口设定为4年，即使用企业前4年内申请的所有专利类别构成已有技术池，因为即使企业在4年前拥有相同技术，相应的知识也会随着时间推移而贬值或过时；第四，和“已有技术池相比”，构建企业当年新领域专利申请规模的自然对数变量 $Patent_new$。为验证基于文本度量的探索式创新是否有助于预测未来企业创新边界的拓展，本文设定如下回归模型：

$$Patent_new_{it+\tau}=\alpha_0+\alpha_1 Text_inv_exp_{it}+\boldsymbol{X}_{it}'\boldsymbol{\alpha}_2+T_t+D_s+\varepsilon_{it+\tau} \tag{8}$$

其中，i 为企业个体，t 为年份，s 为企业所属行业。$Patent_new_{it+\tau}$ 为企业 τ 年后新领域专利申请规模，衡量了创新边界的拓展程度；$Text_inv_exp_{it}$ 为企业的探索式创新度量，本文同时考虑基于探索

①上市公司依据其某类业务的营业收入比重进行行业分类，当企业从事多个不同业务、不能按照上述分类方法确定行业归属的企业，划为综合类行业。

②因篇幅所限，探索式创新词典以附表11展示。

中国知网　https://www.cnki.net

式创新的基准词典和拓展词典两种度量方式，其余设定和基准模型相同。

表7报告了文本探索式创新指标对企业下一期创新边界拓展的预测效果，其中列（1）和列（2）报告了基于基准词典度量的探索式创新的回归结果，列（3）和列（4）报告了基于拓展词典度量的探索式创新回归结果。可以发现，探索式创新的回归系数均显著为正，说明基于文本度量的探索式创新与企业未来新领域专利数量显著正相关，这表明本文基于文本构建的探索式创新变量具有一定的准确性与合理性。

表7　　**探索式创新与企业创新边界**

	$Patent_new_{it+1}$			
	（1）	（2）	（3）	（4）
探索式创新（基准词典度量）	19.5047***（2.7686）	8.0515***（2.4712）		
探索式创新（拓展词典度量）			20.5651***（2.6571）	9.9511***（2.3884）
观测量	36632	36381	36632	36381
R^2	0.1906	0.2497	0.1908	0.2498

六、结论和启示

本文基于2008—2022年我国A股上市公司年报MD&A文本信息，构建微观层面的文本创新指标。相比于传统数据，利用年报文本对于企业经营活动的描述，能够将企业创新的测度范围拓展到所有上市公司，拓展现有我国情境下创新经济学的实证研究思路。本文的方法还能够依据文本的上下语义有效捕捉企业各不同维度的创新活动，进而识别不同特定类型创新活动的相关信息。此外，本文尝试利用文本数据构造企业的探索式创新指标，发现其能较好地预测未来企业技术边界的拓展。综上所述，使用文本这一非结构化数据构建上市公司创新活动指标，在存在研发操纵、数据缺失现象的情况下尤为重要。

根据研究结论，本文得到以下三点启示。一是利用数字技术赋能，构建多维度企业创新评估体系。基于数字化技术开发大数据创新监测平台，实时跟踪和评估企业创新动态，通过对文本等非结构化多模态数据分析，捕捉更多维度的创新活动，并以此构建更科学的创新指标，从而提升政策执行的精准性和有效性。二是推动企业信息披露透明化。相关监管部门应加强对企业各项经营活动信息的披露要求，确保企业创新活动的相关信息更加透明和全面。这不仅有助于政策制定者更科学地优化创新政策，还能为投资者和其他利益相关者提供更准确的企业创新画像。三是加大对非专利创新形式的支持力度。重点关注管理创新、业务模式创新等隐性非传统创新领域，完善相关激励机制，增强企业在多维度创新中的活力与动力。

参考文献

[1] 郭冬梅, 王继彬, 胡瀚清, 等. 基于文本的创新测度及对企业绩效的影响研究[J]. 系统工程理论与实践, 2024, 44(6): 1896–1912.
[2] 姜付秀, 王运通, 田园, 等. 多个大股东与企业融资约束——基于文本分析的经验证据[J]. 管理世界, 2017, 33(12): 61–74.
[3] 姜富伟, 胡逸驰, 黄楠. 央行货币政策报告文本信息、宏观经济与股票市场[J]. 金融研究, 2021, 492(6): 95–113.
[4] 李成明, 周迪, 董志勇. 资本市场开放推动企业数字化转型了吗?——基于准自然实验和文本分析方法[J]. 统计研究, 2023, 40(8): 96–109.
[5] 林乐, 谢德仁. 分析师荐股更新利用管理层语调吗?——基于业绩说明会的文本分析[J]. 管理世界, 2017, 33(11): 125–145.
[6] 沈坤荣, 林剑威, 傅元海. 网络基础设施建设、信息可得性与企业创新边界[J]. 中国工业经济, 2023(1): 57–75.
[7] 王靖一, 黄益平. 金融科技媒体情绪的刻画与对网贷市场的影响[J]. 经济学（季刊）, 2018, 17(4): 1623–1650.
[8] 吴超鹏, 唐苗. 知识产权保护执法力度、技术创新与企业绩效——来自中国上市公司的证据[J]. 经济研究, 2016, 51(11): 125–139.
[9] 吴非, 胡慧芷, 林慧妍, 等. 企业数字化转型与资本市场表现——来自股票流动性的经验证据[J]. 管理世界, 2021, 37(7): 130–144.

中国知网　https://www.cnki.net

[10] 谢德仁, 林乐. 管理层语调能预示公司未来业绩吗?——基于我国上市公司年度业绩说明会的文本分析[J]. 会计研究, 2015(2): 20−27.
[11] 姚加权, 张锟澎, 郭李鹏, 等. 人工智能如何提升企业生产效率?——基于劳动力技能结构调整的视角[J]. 管理世界, 2024, 40(2): 101−116.
[12] 叶初升, 孙薇. 中国“科技创新困境”再审视: 技术创新质量的新视角[J]. 世界经济, 2023, 46(8): 80−107.
[13] 张成思, 孙宇辰, 阮睿. 宏观经济感知、货币政策与微观企业投融资行为[J]. 经济研究, 2021, 56(10): 39−55.
[14] Bellstam G, Bhagat S, Cookson J A. A Text-Based Analysis of Corporate Innovation[J]. Management Science, 2021, 67(7): 4004−4031.
[15] Byun S K, Oh J-M, Xia H. Incremental vs. Breakthrough Innovation: The Role of Technology Spillovers[J]. Management Science, 2021, 67(3): 1779−1802.
[16] Chen Z, Liu Z, Suárez Serrato J C, et al. Notching R&D Investment with Corporate Income Tax Cuts in China[J]. American Economic Review, 2021, 111(7): 2065−2100.
[17] Durnev A, Mangen C. The Spillover Effects of MD&A Disclosures for Real Investment: The Role of Industry Competition[J]. Journal of Accounting and Economics, 2020, 70(1): 101299.
[18] Ellingsen J, Larsen V H, Thorsrud L A. News Media Versus FRED-MD for Macroeconomic Forecasting[J]. Journal of Applied Econometrics, 2022, 37(1): 63−81.
[19] Gentzkow M, Kelly B, Taddy M. Text as Data[J]. Journal of Economic Literature, 2019, 57(3): 535−74.
[20] Hassan T A, Hollander S, Van Lent L, et al. Firm-level Political Risk: Measurement and Effects[J]. The Quarterly Journal of Economics, 2019, 134(4): 2135−2202.
[21] Hoberg G, Maksimovic V. Redefining Financial Constraints: A Text-based Analysis[J]. The Review of Financial Studies, 2015, 28(5): 1312−1352.
[22] Hoberg G, Phillips G. Text-based Network Industries and Endogenous Product Differentiation[J]. Journal of Political Economy, 2016, 124(5): 1423−1465.
[23] Lerner J, Seru A. The Use and Misuse of Patent Data: Issues for Finance and Beyond[J]. The Review of Financial Studies, 2022, 35(6): 2667−2704.
[24] Li F. The Information Content of Forward-Looking Statements in Corporate Filings—A Naïve Bayesian Machine Learning Approach[J]. Journal of Accounting Research, 2010, 48(5): 1049−1102.
[25] Loughran T, McDonald B. When is a Liability not a Liability? Textual Analysis, Dictionaries, and 10-Ks[J]. The Journal of Finance, 2011, 66(1): 35−65.
[26] Loughran T, McDonald B. Measuring Readability in Financial Disclosures[J]. The Journal of Finance, 2014, 69(4): 1643−1671.
[27] Mikolov T, Sutskever I, Chen K, et al. Distributed Representations of Words and Phrases and Their Compositionality[J]. Advances in Neural Information Processing Systems, 2013, 26.
[28] Romer P M. Endogenous Technological Change[J]. Journal of Political Economy, 1990, 98(5, Part 2): S71−S102.
[29] Saidi F, Žaldokas A. How does Firms' Innovation Disclosure Affect Their Banking Relationships?[J]. Management Science, 2021, 67(2): 742−768.
[30] Schumpeter J A. The Theory of Economic Development[M]. Cambridge, MA: Harvard University Press, 1934.

作者简介

谢佳松，东北财经大学经济学院副教授。研究方向为创新与发展经济学、大语言模型应用与自然语言处理。
樊嘉诚，中山大学岭南学院博士研究生。研究方向为预期管理与宏观经济、大数据分析与机器学习。
林建浩（通讯作者），中山大学岭南学院教授。研究方向为宏观金融、发展经济学、计量经济学。电子邮箱: linjh3@mail.sysu.edu.cn。

(责任编辑: 张艺馨)

中国知网　https://www.cnki.net